## 上海交通大学硕士学位论文

## 非平行语料下的语音转换研究

硕士研究生: 吴松泽

学 号: 117033910123

导 师: 俞凯教授

申请学位:工学硕士

学 科: 计算机技术

**所 在 单 位**: 电子信息与电气工程学院计算机系

答辩日期: 2019年12月xx日

授予学位单位:上海交通大学

## Dissertation Submitted to Shanghai Jiao Tong University for the Degree of Master

# INVESTIGATION ON NON-PARALLEL CORPUS BASED VOICE CONVERSION

**Candidate:** Songze Wu

**Student ID:** 117033910123

**Supervisor:** Prof. Kai Yu

Academic Degree Applied for: Master of Engineering

**Speciality:** Computer Science

**Affiliation:** SEIEE

**Date of Defence:** Dec. 17th, 2019

**Degree-Conferring-Institution:** Shanghai Jiao Tong University

## 上海交通大学 学位论文原创性声明

本人郑重声明: 所呈交的学位论文, 是本人在导师的指导下, 独立进行研究 工作所取得的成果。除文中已经注明引用的内容外, 本论文不包含任何其他个人 或集体已经发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体, 均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

学位论文作者签名: 工工 年 工 月 工 日

## 上海交通大学 学位论文版权使用授权书

本学位论文作者完全了解学校有关保留、使用学位论文的规定,同意学校保留并向国家有关部门或机构送交论文的复印件和电子版,允许论文被查阅和借阅。本人授权上海交通大学可以将本学位论文的全部或部分内容编入有关数据库进行检索,可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。

		保	密□,	在	_ 年解領	密后适用	本授权	书。
本学位记	<b>企文属</b>	于						
		不住	保密 □。					
(请在以	上方框	内打	" <b>✓</b> ")					
学位论文作者	皆签名	•		指导	<b>异教师签</b>	名:		
日期:	年	月	目	日其	期:	年	月	日

## 非平行语料下的语音转换研究

## 摘要

语音转换 (Voice Conversion, VC) 是指在不改变语音中语义信息的情况下,通过改变语音的音色和音调,将语音中的原始说话人信息改变为特定的目标说话人。语音转换技术广泛应用于语音信号处理领域,尤其是在个性化语音合成、发音协助、语音增强、多媒体娱乐等领域有着非常广阔的应用前景。根据训练数据条件的不同,语音转换分为平行语料的语音转换和非平行语料的语音转换,平行语料的语音转换一般指已有的原始说话人和目标说话人的语料拥有相同的文本内容,而非平行语料的语音转换则不具备相同文本的语料条件。由于平行语料收集的成本和难度往往较大,非平行语料的语音转换由于其更贴近实际应用场景而在近年成为了语音转换任务的研究热点和难点。本研究以 CycleGAN 语音转换方法为基础,主要探索两个方面:标准非平行语料的语音转换和跨语种的语音转换。

本文针对标准 CycleGAN 语音转换框架,提出半优化 CycleGAN 模型和基频辅助特征。半优化 CycleGAN 模型通过非一致更新来提升转换模型性能;同时通过引入基频信息来提升模型对音调的表达和转换能力。本文在中文数据集上验证所提出的方法。实验表明,半优化 CycleGAN 模型和基频辅助特征在主观测试和客观指标上均好于基线系统,消融测试也证明了两个改进各自带来的提升。

对于难度更大的跨语种语音转换,本文针对跨语种领域差别较大的问题,提出在 CycleGAN 中引入说话人特征的方法。通过可以前向传播和反向计算梯度的预训练说话人特征 d-vector 提取器,来作为判别器的前置网络,使得判别器可以直接通过说话人特征来消除说话人之外的特征差异。实验表明,d-vector 的引入可以在转换说话人信息的前提下,有效提升转换语音的语义。

关键词:语音转换,非平行语料,CycleGAN

## INVESTIGATION ON NON-PARALLEL CORPUS BASED VOICE CONVERSION

#### **ABSTRACT**

Voice Conversion (VC) is a technique to change the original speaker information into a specific target speaker by changing the timbre and tone while preserving linguistic information. VC is widely applied in the field of speech processing, especially in stylied text-to-speech, speech assistance, speech enhancement, multimeida entertainment and so on. VC can be divided into two tasks based on the data condition: parallel VC and non-parallel VC. Parallel means the same content information between source and target corpus, which in non-parallel VC is different. In practical applications, collecting parallel corpus is usually harder than non-parallel corpus. Thus non-parallel VC has attracted attention of increasing amount of research interests in recent years. This paper mainly focus on two parts of non-parallel VC based on CycleGAN VC framework: standard non-parallel VC and cross-lingual VC.

In this paper, a Semi-optimized CycleGAN and Fundamental Frequency (F0) auxiliary features are proposed for the standard non-parallel VC. The Semi-optimized CycleGAN improves conversion performance by using non-consistency optimization; F0 auxiliary features are proposed to improve pitch conversion performace. Experiments are carried out in the Mandarin dataset. The evaluation experiment shows that Semi-optimized CycleGAN and F0 auxiliary features have significantly better performance than baseline CycleGAN system in both subjective and objective evaluations.

For the cross-lingual VC which is more diffcult, a method of introducing speaker features into CycleGAN is proposed to bridge great difference between two acoustic domains. A pre-trained d-vector extractor, which can broadcast both forward and backward, is added as the prenet of Discriminators, which can shrink the acoustic domain to the speaker domain by eliminating residual information. Experiments demonstrate that the usage of d-vector can effectively keep the linguistic information of converted speech while converting speaker identities.

KEY WORDS: SJTU, master thesis, XeTeX/LaTeX template

## 目 录

第一章	绪论
1.1	研究背景和意义
1.2	国内外研究现状
1.3	研究内容和创新点
1.4	章节安排
第二章	语音转换系统
2.1	概述
2.2	语音分析和合成方法 1
	2.2.1 源滤波器模型 1
	2.2.2 数字信号声码器
	2.2.3 神经网络声码器
2.3	特征对齐
2.4	声学特征转换方法
	2.4.1 混合高斯模型法
	2.4.2 码本映射法
	2.4.3 频率弯折法 1
	2.4.4 神经网络法
2.5	韵律转换 2
	2.5.1 基频转换
	2.5.2 时长转换
2.6	本章小结
第三章	非平行语料的语音转换 2
3.1	引言
3.2	非平行语料语音转换概述
3.3	常见特征转换方法
	3.3.1 音素后验概率图法
	3.3.2 对抗训练法
	3.3.3 变分自编码器法

#### 上海交通大学硕士学位论文

3.4	基于 CycleGAN 的语音转换方法	30
	3.4.1 对偶学习概述	31
	3.4.2 生成对抗网络简介	32
	3.4.3 CycleGAN 网络的训练	33
	3.4.4 门控卷积网络和身份损失	33
3.5	本章小结	34
第四章	基于半优化 CycleGAN 的非平行语料语音转换	35
4.1	引言	35
4.2	基于梅尔频谱 WaveNet 的平行语料语音转换	35
	4.2.1 WaveNet 声码器	35
	4.2.2 梅尔频谱特征转换	37
4.3	基于半优化 CycleGAN 的非平行语料语音转换系统	38
	4.3.1 半优化周期一致性生成对抗网络	39
	4.3.2 基频辅助特征	41
4.4	实验分析	42
	4.4.1 实验配置	42
	4.4.2 客观评测	44
4.5	主观评测	45
4.6	本章小结	48
第五章	基于说话人特征的跨语种语音转换优化方法	49
5.1	引言	49
5.2	。。 跨语种语音转换	49
	5.2.1 跨语种语音转换概述	49
	5.2.2 跨语种语音转换的难点	50
5.3	说话人识别	51
	5.3.1 说话人识别概述	51
	5.3.2 d-vector 说话人特征	51
5.4	引入说话人特征的跨语种语音转换	51
	5.4.1 语种无关的 d-vector 提取器训练	51
	5.4.2 d-vector 提取器和 CycleGAN 的结合	51
5.5	实验分析	51
	5.5.1 实验配置	51

#### 上海交通大学硕士学位论文

	5.5.2	引入i	兑话人	、特征	E的a	有效'	性检	验	 		 		 		51
	5.5.3	说话。	人分类	模型	则的比	化较			 		 		 		51
5.6	本章小	结 .							 		 	•	 	·	51
全文总统	结								 		 		 		53
Maxwel	ll Equati	ions .							 		 	•	 		55
绘制流	程图				• •				 		 	•	 	•	57
参考文	献				• •				 		 	•	 	•	59
致 谢									 		 	•	 	•	69
攻读硕:	士学位其	月间已2	发表或	录用	的i	仑文			 		 	•	 		<b>7</b> 1
攻读硕:	士学位期	朋间参	与的项	目					 		 		 		73
攻读硕:	士学位其	月间 申i	清的专	利					 		 	•	 		75
简 历									 		 		 		77

## 插图索引

冬	2-1	语音转换系统示意图	9
图	2–2	源滤波器模型示意图	12
图	2–3	STRAIGHT 声码器模型框架	13
图	2–4	WaveNet 自回归示意图	15
图	2–5	DTW 算法序列对齐示意图	17
图	2–6	多层感知机结构图	20
图	2–7	长短时记忆网络结构图	21
图	3–1	音素后验概率图语音转换方法示意图	27
图	3–2	变分自编码器语音转换方法示意图	29
图	3–3	标准 CycleGAN 示意图	30
图	4–1	WaveNet 模型结构图 <sup>[25]</sup>	36
图	4–2	梅尔频谱语音转换和传统语音转换对比图	37
图	4–3	不同特征和声码器下语音转换对比图[68]	38
图	4–4	基于半优化 CycleGAN 的语音转换系统结构图	39
图	4–5	标准 CycleGAN 中最小更新过程示意图	40
图	4–6	标准 CycleGAN 和半优化 CycleGAN 重构损失函数的对比图	41
图	4–7	半优化 CycleGAN 网络结构图	43
图	4–8	标准 CycleGAN 和半优化 CycleGAN 在训练过程中梅尔频谱距	
		离的对比	45
图	4–9	不同方法在语音自然度上的平均主观意见分对比图	47
图	4–10	不同大小训练数据集在语音自然度上的平均主观意见分对比图.	48
图	4–11	不同系统在四个说话人对上的相似度对比图	48
图	5–1	跨语种语音转换和标准语音转换对比图	50
圂	<b>-2</b> .	<b>绘制流程图效果</b>	57

## 表格索引

表 2-1	常用语音转换声学特征示例	11
表 4-1	Comparison of MSE, mean and standard deviation between target and	
	converted FO	46

## 算法索引

## 主要符号对照表

- ← 介电常数
- μ 磁导率
- $\epsilon$  介电常数
- μ 磁导率

- $\epsilon$  介电常数
- μ 磁导率
- ϵ 介电常数
- μ 磁导率
- ← 介电常数
- μ 磁导率
- ← 介电常数
- μ 磁导率
- ϵ 介电常数
- μ 磁导率
- ϵ 介电常数
- μ 磁导率
- ← 介电常数
- μ 磁导率
- $\epsilon$  介电常数
- μ 磁导率
- $\epsilon$  介电常数
- μ 磁导率
- $\epsilon$  介电常数
- μ 磁导率
- ϵ 介电常数
- μ 磁导率
- $\epsilon$  介电常数
- μ 磁导率

## 第一章 绪论

语音是人类交流最常用、最直接、最有效的信息载体之一。在信息数字化时代,科学家们致力于将这种最有效的交流方式应用于人机交互中,使得人类可以直接通过语音来与不同的机器设备交互,即语音人机交互。随着人工智能时代的到来,简单的人机交互已经不能满足人们的需要,智能化,个性化已经成为语音人机交互的发展方向。对于机器而言,一个人机交互的完整流程通常包括语音识别、语义理解、对话管理和语音合成四个步骤。其中语音合成作为交互的最后一个环节,主要负责将机器生成的文本转换成语音反馈给用户。其中,所生成语音的个性化程度是影响人机交互体验的重要因素。语音转换即可以通过对语音中的说话人特性进行调整和修改,用相对较少的数据实现对语音的个性化生成。

在深度学习的影响下,语音转换技术也得到了飞速的发展,并在个性化语音合成、发音协助、语音增强、多媒体娱乐等有着广泛的应用前景。根据数据条件的不同可以分为平行语料的语音转换和非平行语料的语音转换。其中,非平行语料的语音转换由于其更符合实际应用场景而在近年受到了越来越多的关注。本章将从问题的研究背景和意义,国内外研究现状以及研究内容和创新点几个方面进行论述。

## 1.1 研究背景和意义

语音通常是指人类发出的包含有语义信息的声音。因此一段语音中所包含的信息可以分为语义信息和非语义信息<sup>[1,2]</sup>。即使有少部分说话人信息存在于语义信息中,如方言,说话风格等,在语音转换中,非语义信息仍和说话人信息有较强的相关性<sup>[3]</sup>。所以当前在语音转换上的研究和实现主要以语音中的非语义信息为转换对象,而其中的语义信息则在转换过程中尽可能完整保留。广义的语音转换可分为非特定人语音转换和特定人语音转换两大类,非特定人的语音转换是指通过处理将原始说话人的语音转换为不像原始说话人的声音,例如老人、小孩、男性、女性等。而在实际应用中,语音转换通常是将原始说话人的语音转换成特定目标说话人的语音,建模难度要高于非特定人语音转换。

根据构造语音转换模型时的数据条件的不同,语音转换可以分为平行语料的语音转换和非平行语料的语音转换。平行语料的语音转换是指原始说话人和目标说话人的训练数据具有相同的文本内容,因此可以做到从原始音频到目标音频的一一对应,实现有监督训练。而非平行语料则假设训练数据没有重叠的文本内容,

对于原始说话人的每一段语音,没有可以作为标签的目标说话人语音,是无监督训练。由于在实际应用中,平行语料的训练数据获取难度大,成本高,而非平行的语料在现实生活中相对较容易收集,非平行语料的语音转换在近两年受到越来越多研究人员的关注,也在深度学习的浪潮下,得到了飞速发展。非平行语料可以进而拆分为语种内非平行语料的语音转换和跨语种的语音转换。在跨语种的语音转换中,原始说话人和目标说话人不仅在说话人信息上有差别,在整体的语义信息上也有着较大的差别,这对转换模型的建模能力提出了更高的要求,目前跨语种语音转换的研究还处于初步阶段。

语音转换作为在近两年发展较快的研究方向,目前还少有非常成熟的商用系统,但其在很多领域都有非常广泛的应用前景,例如:

- **个性化语音合成:** 语音转化可以帮助实现个性化语音合成。语音合成 (Textto-Speech, TTS) 是指通过输入说话人无关的文本,来得到某个特定说话人 的对应语音。对于当前语音合成技术的发展,通常使用特定说话人十几到几 十个小时的经过标注的训练数据就可以合成自然度和相似度很高的语音。 但大量的训练数据和人工标注工作,使得构建语音合成模型的成本极高,这 对于普通人而言是极难实现的。对于这类问题,通常有两种解决思路,第 一种是对语音合成模型进行调整来使得其可以合成另一个人的声音,常见 的做法包括构建多说话人的语音合成模型[4-6] 以及说话人自适应方法[7-9]。 该方法可以通过较少的数据实现个性化语音合成,但依旧无法避免标注成 本,且训练语音合成模型也需要较长的时间。另一种方法则是利用语音转 换技术[10,11]。语音转换技术通常只需要说话人很少的数据(几十分钟至几 小时) 就可以得到一个效果不错的语音转换模型,且语音转换的训练不需 要文本标注,模型复杂度也小于语音合成模型。因此可以利用语音转换的 优势,仅需要目标说话人少量的数据,训练语音合成模型说话人到目标说 话人的语音转换模型,便可以使用语音合成模型生成原始说话人的声学特 征序列,再通过语音转换模型得到目标说话人的特征序列。
- **发音援助**:语音转换可以帮助发音障碍人群更好的交流,提高语音的可懂度。每1000个新生儿中就有2-3个患有大脑性瘫痪,其中有10%-15%属于痉挛性脑瘫。这种脑瘫会限制肢体动作的正常表现,而与发音相关的肢体运动则会导致说话不稳定,不清晰<sup>[12,13]</sup>。受到发音障碍困扰的痉挛性脑瘫患者通常只能通过语气词和写字交流。由于发音障碍主要来自于辅音部分,因此则可以通过语音转换技术将原始的辅音部分转换为正常说话人的声学特征,元音保持不变,这样则可以很大程度提升障碍语音的清晰度。

- **语音翻译**:语音转换可以实现更完备的语音翻译。在深度学习的帮助下,机器翻译技术也得到了迅速的发展。在实现高质量,高准确率的翻译下,机器翻译也逐渐涉及到更多的语种,同时为了能够实现更便捷的交流,语音翻译也成为了机器翻译的重要应用方向。一个语音翻译系统通常需要语音识别,机器翻译,语音合成三个技术的支持。直观上,语音翻译生成的声音,应与输入语音的说话人保持一致,然而对于语音合成系统,要合成输入语音的说话人,则面临训练数据量和跨语种两个挑战。原始说话人的训练数据量通常很少,即使有较多的数据,目前在跨语种的语音合成依旧没有较好的解决方案。因此可以使用跨语种语音转换技术将语音合成的第三方说话人转换为输入语音的说话人,实现真正的只改变语义,保留说话人信息不变的语音翻译系统<sup>[14]</sup>。
- **声纹识别**:语音转换可以提升声纹识别系统的鲁棒性。除了传统的指纹加密、字符加密等外,利用语音来识别身份作为加密的方式也引起了人们的兴趣,因而说话人识别和验证也越来越受到重视。出于实际应用的考虑,将无关说话人识别为正确说话人是难以接受的,因而说话人验证系统很容易收到各种各样的攻击,比较典型的包括重放攻击 (replay attack)和语音转换攻击。其中语音转换攻击通过将无关说话人的语音转换为目标说话人的语音来欺骗声纹识别系统,同样转换出来的语音可以作为声纹识别的负例样本来减少声纹识别的误判率<sup>[15]</sup>。同理,声纹识别也可以对语音转换的相似程度做出判定。声纹识别和语音转换可以看做互为对抗任务,语音转换尽可能转换更接近目标说话人的语音,而声纹识别则需要尽可能的识别出最先进的语音转换系统转换出来的语音。

## 1.2 国内外研究现状

语音转换始于二十世纪80年代,在三十多年各国研究人员的不断努力下,语音转换模型和方法在不断的进步和完善。随着近几年深度学习的发展,语音转换技术经历了一次爆发,基于神经网络的方法被不断提出。为了使世界各地的研究者可以相互比较各自的系统,使语音转换技术可以更好的发展,2016年研究人员自发举办了第一届语音转换挑战赛(Voice Conversion Challenge, VCC),参赛团队要求在给定的数据集上开发语音转换系统,由官方对所有系统性能进行对比<sup>[16,17]</sup>。在第一届VCC之后,越来越多的研究人员开始投入到语音转换的研究当中,随着技术发展的不断深入,语音转换也逐渐产生了更细的分化,包括一对一、多对一、多对多、任意对一语音转换等,代表语音转换系统可以实现转换的原始说话人和

目标说话人的数目。最初的语音转换任务主要专注于平行语料的语音转换,即原始说话人和目标说话人的训练数据具有相同的文本内容。然而在技术落地时,研究人员逐渐发现在实际的应用场景中,获取平行语料的成本非常高,而且平行语料之间差别过大也会严重对齐效果,从而影响语音转换的性能。因此,语音转换的研究重心逐渐由平行语料向非平行语料倾斜。在 2018 年的第二届语音转换挑战赛上,非平行语料的语音转换被添加到挑战项目中<sup>[18]</sup>。

如前文所述,语音转换需要尽可能保留原始语音中的语义信息,通过对其中的非语义信息变换来改变说话人身份。一个完整的语音转换系统包括训练模块和转换模块两部分。训练模块包括训练数据特征提取和预处理,特征对齐和转换模型训练三个步骤。转换模块包括输入数据特征提取和预处理,声码器合成和特征转换这三个部分。因此,声学特征对齐的准确度、转换模型的转换性能和声码器的合成性能是决定语音转换音质和相似度的三大因素。

特征对齐主要应用于平行语料的语音转换任务中。相同语义信息的原始和目标音频长度往往是不一致的,就会导致不同长度的特征序列在学习映射函数时无法做到帧级别的一一对应。为了更精准的对齐,常使用动态时间规整算法(Dynamic Time Warping, DTW)对两者进行对齐,得到的对齐路径再通过复制或插值的方式将两个序列对齐到同一长度。对于非平行语料的语音转换,会根据不同的模型使用不同的对齐方式,如无监督聚类法<sup>[19]</sup>,监督迭代法<sup>[20]</sup> 和音素对齐法<sup>[21]</sup>。

声码器是语音信号的分析合成系统,通过对语音信号进行分析,提取出语音信号的不同声学特征,同时也可以通过声学特征重建波形。传统的声码器以数字信号处理算法为基础,将输入的语音信号通过傅里叶变换分析成具有不同意义的特征,如基频、频谱、非周期信号、倒谱等。常用的数字信号声码器包括 STRAIGHT<sup>[22]</sup>、tandemSTRAIGHT<sup>[23]</sup>、WORLD<sup>[24]</sup>等。近年来,基于深度学习的声码器在生成语音的自然度上已经能够接近真实音频,使得语音生成相关的任务在性能上整体得到了提升。神经网络声码器通过大量语音数据建模声学特征和音频样本点之间的关系,除了合成音质显著好于传统声码器之外,神经网络声码器的输入特征可以根据具体任务进行修改和优化,甚至可以实现文字转语音的任务。常用的神经网络声码器包括 WaveNet<sup>[25-27]</sup>、WaveRNN<sup>[28]</sup>、LPCNet<sup>[29]</sup>等。声码器的性能判断主要包括重构语音的音质,鲁棒性和生成实时率。

特征转换是语音转换中的核心和关键,转换模型的好坏会直接影响语音转换 系统的性能。如前文所述,特征转换需要在转换过程中保持语义信息不变,只修 改特征中的说话人相关特征,由于并没有显式的说话人特征存在,因此如何只修 改特征中的说话人信息而保持其他信息不变则是特征转换部分的主要挑战。研究 人员提出了很多不同的方法来解决这个问题。

平行语料的转换方法主要可以分为四大类:基于实例化的转换、基于规则的转换、基于概率统计的转换和基于神经网络的转换。基于实例化的方法主要有单元选择法 (Unit Selection)<sup>[30-32]</sup> 和基于非负矩阵分解法 (Non-negative Matrix Factorization, NMF)<sup>[33-35]</sup>。基于规则的方法则是频率弯折法 (Frequency Warping, FW)<sup>[30, 36-38]</sup>。基于概率统计的方法主要是指高斯混合模型法 (Gaussian Mixture Model, GMM)<sup>[10, 39-41]</sup>。基于神经网络的方法在近两年发展迅速,许多不同的模型都被提出可以实现语音转换的任务,包括人工神经网络 (Artificial Neural Networks, ANN)<sup>[14]</sup>、深度神经网络 (Deep Neural Networks, DNN)<sup>[42, 43]</sup>、循环神经网络 (Recurrent Neural Networks, RNN)<sup>[44, 45]</sup>、卷积神经网络 (Convolution Neural Networks, CNN)<sup>[46]</sup>,生成对抗网络 (Generative Adversarial Network, GAN)<sup>[46, 47]</sup>、序列到序列 (Sequence-to-Sequence)<sup>[48-50]</sup> 和基于 WaveNet 的方法<sup>[51]</sup>。

非平行语料的转换方法可以分为三大类:基于音素后验概率图 (Phone PosteriorGram, PPG) 的方法、基于对抗学习 (Adversarial Learning) 的方法和基于变分自编码器 (Variational AutoEncoder, VAE) 的方法。基于音素后验概率图的方法主要是通过语音识别模型从目标说话人的声学特征中提取说话人无关的语义信息,然后再直接学习从语义信息到目标说话人的声学特征的映射关系<sup>[52]</sup>。语义信息的表示即声学建模单元的后验概率,可以根据不同任务选择不同的建模单元,也可以根据不同的声码器进行不同的优化<sup>[53-56]</sup>。基于对抗学习的方法主要受对偶学习的思想启发,通过同时学习若干个对偶任务来达到无监督学习的目的。包括一对一转换 CycleGAN<sup>[57,58]</sup> 和多对多转换 StarGAN<sup>[59,60]</sup>。基于变分自编码器的方法通过在变分自编码器的中间变量中加入说话人表示,来实现无监督的说话人风格转换<sup>[61,62]</sup>。将变分自编码器和对抗学习相结合<sup>[47]</sup>,变分自编码器和音素后验概率图相结合<sup>[63]</sup> 的方法也被提出。

对于转换的声学特征,常用的方法是使用声码器分析出梅尔倒谱,基频,非周期信号三个特征,这三个特征分别做不同的处理:梅尔倒谱使用转换模型进行转换,基频使用均值方差线性缩放的方式进行转换,非周期信号保持不变。三个特征分别处理后再使用声码器合成为波形。近年随着神经网络声码器的发展,直接使用频谱建模也可以得到较为不错的转换语音。

虽然语音转换技术越来越成熟,方法也越来越多样化,但是当前技术仍旧存 在较多挑战:

 DTW 的对齐方式准确度较差,尤其是当需要对齐的两句话差别较大时,对 齐往往有较大的误差,这对转换模型的学习有直接的影响。

- 尽管当前非平行语料的语音转换方法可以实现较好的语音转换,但转换语音整体的自然度和相似度依旧有较高的提升空间。如何在有限的数据条件下尽可能提升转换模型的建模能力是当前主要的研究方向。
- 由于转换特征和真实特征之间的分布差异,导致声码器在转换特征上合成的声音音质较差。该问题一方面需要从声码器的鲁棒性角度入手,尽可能提升声码器对带噪声声学特征的适应能力,另一方面则是通过改进转换模型来缩小转换特征和真实特征之间的距离。
- 传统的线性变换对基频而言是较为简单和直接的,但实际上音调的变化往往是更为复杂的,需要更多非线性变换来进行更为准确的基频转换。

#### 1.3 研究内容和创新点

本文将在 CycleGAN 模型的基础上,对非平行语料和跨语种语料下的语音转换任务分别提出了不同的训练模型和框架。

- 对于标准的非平行语音转换,原始和目标语料属于同一语种。本文首次将CycleGAN模型与基于梅尔频谱的WaveNet声码器结合,并使用包含基频信息的梅尔频谱特征作为声学特征,该方法不仅能提升转换语音的上限,还可以实现基频的隐式转换。通过分析标准CycleGAN模型的训练和更新方式,提出半优化CycleGAN模型,该模型优化标准模型训练中的部分更新过程,可以在不改变模型结构的条件下,明显提升转换语音的自然度和相似度。针对转换时出现的发音错误问题,同时提出使用基频辅助特征帮助生成器和判别器更好地实现基频转换。
- 对于跨语种语音转换,原始和目标语料属于不同语种。对于跨语种这类原始和目标领域相差较大的情况,判别器在训练时很容易更偏向于区分领域差异,而不是说话人差异,从而导致转换效果较差,甚至无法有效转换。针对该问题,本文引人说话人识别中的说话人特征 d-vector,来过滤掉特征中的领域差异。使用不同说话人数据预训练 d-vector 提取器,将训练结束的d-vector 提取器作为 CycleGAN 中判别器的前置网络,并保持参数固定。说话人特征的引入减小了正负例之间的领域差异,使得判别器可以直接对说话人特征进行判断,有效地提升了转换性能。

## 1.4 章节安排

本文章节内容安排如下:

第一章 绪论:首先简要介绍了语音转换的研究背景,介绍了当前存在的应用场景;接着介绍了语音转换的发展历史,简要介绍了语音转换中的几个重要部分:特征对齐、声码器、特征转换和体征提取,及其当前的研究进展。最后简要描述了本文的主要研究工作和贡献。

第二章 语音转换系统:介绍了语音转换系统各个部分的技术细节,总结和对比了当前在语音分析与合成,特征对齐,特征转换和韵律转换上的传统和前沿做法。

第三章 非平行语料的语音转换:对语音转换中非平行语料的语音转换进行详细描述。介绍和对比了当前常见的特征转换方法,并详细描述了基于 CycleGAN 的语音转换方法,这也是本文所采用的方法。

第四章 基于半优化 CycleGAN 的非平行语料语音转换:本章详细阐述了本文提出的基于半优化 CycleGAN 的非平行语料语音转换方法。包括采用基于梅尔频谱的 WaveNet 模型作为声码器,半优化 CycleGAN 模型以及基频辅助特征。最后介绍实验配置和描述主观实验和客观实验的结果。

第五章 基于说话人特征的跨语种语音转换优化方法:本章详细阐述了本文设计的基于说话人特征的跨语种语音转换方法。首先介绍了跨语种语音转换及其难点;接着介绍了说话人识别和 d-vector 的相关概念;然后详细描述了引入说话人特征的跨语种语音转换方法;最后对主观实验和客观实验的实验进行配置介绍和结果分析。

## 第二章 语音转换系统

#### 2.1 概述

如前文所述,语音转换是一种在保持语音中文本内容不变的前提下,将语音中的说话人信息转变为另一说话人信息的技术。目标说话人可以是特定说话人,也可以是非特定的。本文将主要讨论特定说话人的语音转换。




图 2-1 语音转换系统示意图

Figure 2–1 Schematic diagram of the voice conversion system

如图 2-1所示,语音转换系统通常包含训练模块和测试模块。在训练阶段,首 先需要从训练数据中提取声学特征,通常使用传统的数字信号声码器实现该部分; 之后将提取出的原始和目标声学特征进行对齐,对齐算法取决于使用的语音转换 方法,有些转换方法也会省略掉对齐步骤;对齐后的特征会放入转换模型中根据 具体的方法进行训练。在测试阶段,测试数据中只有原始说话人的数据,首先用 声码器提取声学特征;然后将特征输入已经训练完成的转换模型中得到转换特征;通常声码器分析出的特征不只一种,有些方法只会转换一部分声学特征,剩下的其他特征需要做其他处理,如线性变换,保持不变等;最后将处理后长度相等的声学特征放入声码器中,得到转换音频。

可以看出,决定语音转换系统性能的主要因素为语音分析和合成方法,特征对齐和转换模型。目前的神经网络声码器已经可以稳定地从真实音频分析的特征中生成非常自然的声音了,因此只要转换模型转换出来的特征足够接近真实,那么声码器就可以等价地生成接近真实的语音。特征对齐对语音转换的性能有着较大的影响,对于序列层面的对齐而言,受到说话人语速、韵律的影响,长度不同的两段特征往往很难做到精准的对齐,错误的对齐则会导致向训练数据数据引入错误的标签。因此,近两年提出了很多绕开特征对齐的语音转换方法。转换模型是语音转换中非常重要的一步,除了能够进可能地转换说话人信息之外,现有的转换模型大多只考虑对说话人信息进行转换,对于韵律特征(如基频,时长)则依旧采用简单的线性变换,这种变换可以得到不错的效果,但很难真实反应目标说话人的韵律变化,因此较为复杂的韵律转换方法也成为语音转换的目标之一。

评价一个语音转换系统的好坏主要根据该系统所转换的语音来判断,一般分为客观指标和主观指标。客观指标一般采用梅尔倒谱失真 (Mel-cepstral Distortion,MCD) 或对数谱失真 (Log-Spectral Distortion, LSD),梅尔倒谱失真计算方法如下,

$$MCD(a^{cvt}, a^{tgt}) = \frac{10\sqrt{2}}{ln10T} \sum_{t=0}^{T-1} \sqrt{\sum_{d=s}^{D} (a^{cvt}_d(t) - a^{tgt}_d(t))^2}$$

其中 a<sup>cvt</sup> 和 a<sup>tst</sup> 分别代表转换特征序列和目标特征序列,T 和 D 分别代表时间维度和特征维度的大小。梅尔倒谱失真的计算方法也可以应用到其他特征的失真计算中,如梅尔频谱失真,失真度越小,系统的性能就越好。客观指标可以一定程度上反应转换特征和真实特征之间的差异程度,但由于语音的质量通常由很多复杂的因素决定,客观指标的计算往往不能充分反应音质的好坏。对于语音生成任务而言,语音的最终接收者是人,因此最能反应生成语音好坏的方法就是主观评价。主观评价测试可以分为主观意见分测试 (Mean Opinion Score, MOS) 和对比测试 (ABX test)。主观评价测试一般由测试人员对音频做出 1 到 5 分的打分,相似度则需要测试人员在候选音频中选择自己更为偏好的一个。通过若干名客观的测试人员对测试音频的两个方面进行打分,分别为自然度和相似度。自然度表示语音是否像是人类发出的声音,具体体现在语音的连贯性,噪音以及音调上。相

似度表示语音中的说话人是否像是目标说话人的声音,具体体现在语音的音色上, 韵律对相似度也有一定的影响。

#### 2.2 语音分析和合成方法

音频的数字形式可以看成一段长度较长的实数序列,序列的长度由音频时长和采样率决定。例如对于 16k 采样率的一秒时长的音频,则可以表示为一个长度为 16000 的向量,直接对音频样本点序列进行建模目前还有比较大的难度。因此通常会基于语音的短时平稳的特性,对样本点序列进行分窗成帧,由于每一窗内的信号可以认为是平稳的,则可以对窗内的信号进行分析提取特征,这样可以大大缩短音频表示的序列长度。因此作为语音转换的主要对象,声学特征的分析对转换模型的建模复杂度和声码器的合成音质都有非常直接的影响。常见的声学特征及其特性如表 2-1所示<sup>[64]</sup>。

表 2-1 常用语音转换声学特征示例

声学特征	注释
线谱信号频率 (LSF)	提供稳定,良好的插值性;与共振峰相关性强;对频谱峰建模
梅尔频率倒谱系数 (MFCCs)	对频谱峰和频谱谷建模;由于对声学距离度量的可靠性, 对特征对齐十分有用
梅尔倒谱系数 (MCCs)	是语音转换和基于 HMM 的语音合成技术中最常用的频谱表示特征之一。在特征对齐上和 MFCCs 类似
共振峰 (Formants)	共振峰的带宽,位置和强度将会是语音转换中非常有用 的特征,但是它们的有效估计仍具有挑战性
频谱采样点	频域的采样点也可以被用作语音转换的特征;一般多用于基于频率弯折的方法中。
基频 (F <sub>0</sub> )	基频和对数基频一般通过均值方差的变换转换到目标说话人
发音标志 (Voicing)	通常二值的发音或非周期信息
激励频谱	有时激励频谱的细节也需要被建模,一般在使用正弦模 型是会被用到。

对于语音的合成方法,可以通过数字信号声码器和神经网络声码器来实现。数字信号声码器通过信号处理的手段从特征合成音频,主要包括 STRAIGHT 声码器, WORLD 声码器和 GL 算法;神经网络声码器则是通过神经网络从大量音频

数据中学习特征与音频样本点之间的关系,包括 WaveNet, WaveRNN, LPCNet 等。 下文将详细介绍源滤波器模型和几种常用的数字信号声码器和神经网络声码器。

#### 2.2.1 源滤波器模型

源滤波器模型是发声理论中非常著名的模型。在源滤波器模型看来,人类的发声过程主要由声道系统完成,可以分为两个阶段:激励和滤波。其中源激励由喉中的声带产生,滤波由声道的谐振特性完成。对于元音而言,声源是由声带周期性震动产生的一定频率的声门声音,声源决定元音的音调和音质,之后由声道和口腔的谐振特性对输入声源进行滤波,得到了不同的元音发音。对于辅音而言,声源主要由气流在声带,咽部等经过时发出的非周期信号组成,滤波部分同元音类似。声源并不是单一的,实际产生的声音中往往包含一个或多个声源。发声是一个动态的过程,当声道配置出现改变时,其谐振特性也会出现改变,随之改变音质和输出的声音。




图 2-2 源滤波器模型示意图

Figure 2–2 Schematic diagram of the source filter model

图 2-2是源滤波器模型的示意图。不管是元音还是辅音,都会涉及到四种声源: 声门周期震动时产生的带有基频的发声源,当空气快速通过开放不震动的声门时产生的气音源,当空气快速通过狭窄的咽部时摩擦产生的摩擦音源,口腔中压力突然改变而产生的瞬时音源。其中发声源属于周期信号源,气音源、摩擦音源和瞬时音源属于非周期信号源。当人类产生声音时,一种或多种音源的组合会作为输入传递给声道滤波,所发出的元音或辅音则可以看做滤波的输出。

如果声道的配置不发生改变,声道滤波部分就会变成一个线性时不变系统 (LTI),同时输出信号 y(t) 可以由输入信号 x(t) 和系统的冲激响应 h(t) 的卷积来表示,也就是

$$y(t) = h(t) * x(t)$$

$$(2-1)$$

转换成频域表达就是

$$Y(\omega) = H(\omega)X(\omega) \tag{2-2}$$

也就是说,语音谱  $Y(\omega)$  是由源谱  $X(\omega)$  和声道滤波谱  $H(\omega)$  的乘积建模而成。严格来讲,声道滤波谱  $H(\omega)$  可以被进一步拆分为声道转换函数  $T(\omega)$  和口腔的发散特性  $R(\omega)$  的乘积,即

$$Y(\omega) = [T(\omega)R(\omega)]X(\omega) \tag{2-3}$$

源滤波器模型对声音的产生给出了很好的解释和模拟,但也存在较多缺陷。一方面是声源信号的实际处理过程涉及到更多复杂的非线性变换,直接的线性操作很难模拟真实语音,同时语音的产生是一个时变的过程,声道的配置根据实际情况不断变化,这些变化的建模也是语音发声的难点之一。但由于源滤波器模型的有效性,其仍受到了广泛的使用。

### 2.2.2 数字信号声码器

数字信号声码器是指利用信号处理技术对音频进行特征分析和重建的一系列技术。由于其通常包含了从语音提取特征和从特征合成语音的一系列功能,从而是语音转换和语音合成等语音生成任务中使用最广泛的一类声码器。接下来将介绍常用的两个数字信号声码器:STRAIGHT, WORLD, Griffin Lim。

• **STRAIGHT**: 全称为自适应内插加权谱的语音转换与重构模型 (Speech Transformation and Representation using Adaptive Interpolation of weiGHTed spectrum),于 1997 年提出<sup>[22]</sup>。




图 2-3 STRAIGHT 声码器模型框架

Figure 2–3 Framework of the STRAIGHT vocoder

STRAIGHT 建立在源滤波器理论上。如图 2-3所示,STRAIGHT 通过语音分析从语音信号中提取出三个独立性较强的特征:基频,幅度谱和非周期信息。其中基频代表上文中激励部分的频率,也代表语音中的音调高低频率;幅度谱代表语音的在各个频率上的福值,可以看成滤波部分中的滤波器分量,决定语音的发音;非周期信息则描述了周期信号和非周期信号之间的比例关系,对语音的自然度有很大的作用。STRAIGHT 在传统源滤波器信道声码器 (VOCODER) 的基础上,通过在时频域对功率谱进行谱补偿的平滑处理,并在时间轴和频率轴上采样,消除自然语音中周期性的方法来提高语谱估计的准确度,进而提升重构语音的音质<sup>[65]</sup>。STRAIGHT 是传统语音生成任务中最常用的声码器之一。

- WORLD: WORLD 于 2016 年作为能够实现高质量实时合成的声码器被提出,由于其在不降低音质的情况下高效的合成速度和免费开源的特性,很快就吸引了大量研究者的使用<sup>[24]</sup>。与 STRAIGHT 类似,WORLD 也是基于源滤波器模型。在 WORLD 中,首先基频轨迹使用 DIO 基频提取算法从音频中估计;然后用 CheapTrick 算法分析频谱,分析频谱时不光需要原始音频,也需要上一步提取的基频;最后用 PLATINUM 算法从原始音频、基频和频谱中估计非周期信息。其中 WORLD 中的非周期信息定义与STRAIGHT 中略有不同,STRAIGHT 中非周期信息是指非周期信号与周期信号之间的比例,而 WORLD 中则是直接将激励信号作为非周期信息。在合成部分,声带振动是在最小相位响应的卷积基和提取的激励信号上计算的,相比 STRAIGHT,卷积计算量更小,使得合成速度也会更快。
- Griffin Lim:Griffin Lim(GL)于 1984年作为一种信号重建算法被提出<sup>[66]</sup>。它可以实现从信号的短时傅里叶变换中估计信号。GL算法的优点是可以直接从频谱构建音频,而不需要预先知道相位信息,相位信息由算法估计。缺点是相位的估计依旧不够精准,合成的声音依旧有较为明显的相位不准的情况。GL算法首先初始化相位,然后通过不断的计算逆傅里叶变换和傅里叶变换来估计相位信息,一般 50 次迭代就可以得到效果不错的音频。但由于算法本质上是一种迭代算法,因此很难做到实时。

目前的数字信号声码器在语音合成的鲁棒性和特征可修改性上都有较好的表现,如 STRAIGHT 可以实现对音调、声道长度和语速等特性进行 600% 的修改而不会导致音质的明显下降。同时 WORLD 在处理速度和实时性上也有较好的表现。但当前数字信号声码器所存在的普遍问题是合成音质与真实音频还有着较大的差距,主要体现在 STRAIGHT 和 WORLD 通常会有较为明显的蜂鸣声,由于基频预

测不准确造成的额外噪音,以及人声的不自然。这些一部分是因为数字信号声码器的实现主要是基于信号处理领域的先验知识,声码器和现实生活中的真实语音并不存在信息交互,由于语音中实际存在大量的复杂信息,仅通过源滤波器模型来模拟语音生成过程是不足以良好的重建语音的。因此基于深度学习的声码器逐渐被提出,其通过学习大量真实数据,使得语音合成的自然度有了飞跃性的提升。

### 2.2.3 神经网络声码器

神经网络声码器是指通过神经网络强大的非线性建模能力,来实现从声学特征到音频的合成技术。不同于数字信号声码器,神经网络声码器通常需要大量的真实音频数据对合成模型进行训练。本文主要介绍两种神经网络声码器: WaveNet和LPCNet。

• WaveNet: WaveNet 于 2016 年由谷歌首次提出,最初是作为音频生成模型来实现自然音频的生成<sup>[25]</sup>。并将其在语音生成,文本转语音,音乐生成和语音识别任务上进行了初步尝试,并在 2017 年被成功应用到声码器上<sup>[26]</sup>。




图 2-4 WaveNet 自回归示意图

Figure 2-4 Schematic diagram of the autoregressive WaveNet

如图 2-4所示,WaveNet 是一种自回归模型,即当前时刻的输出取决于之前历史的输出。每一个时刻模型会通过音频历史的样本点来预测当前的样本点。由于音频的样本点非常密集,一秒种的音频就有上万个样本点,这对自回归模型而言建模难度非常大,因此 WaveNet 提出使用扩张的因果卷积来增加模型的感受域。因果是指模型只会将历史样本点作为输入,预测当前样本点;扩张是指模型会在每层将相隔一定距离的样本点作为输入,而

不是将所有样本点作为输入。例如图 2-4中隐藏层从低到高扩张因子分别为 1, 2, 4, 8, 即为 2 的 n 次方,这样可以使得每一层只有两个输入的情况下,只用 4 个隐层便达到 16 的感受域。

WaveNet 也可以通过在每一层添加额外的输入来实现在音频生成的过程中加入条件向量,该条件向量即可以是句子级别的,也可以是帧级别的,分别对应全局条件和局部条件。在 WaveNet 声码器中,条件向量可以是任何声学特征,全局向量可以代表说话人,实现多说话人的声码器。WaveNet 可以生成非常接近自然的语音,但是其缺点也非常明显,WaveNet 生成时间较长,很难实现实时生成,因此一些提升 WaveNet 生成效率的改进也被提出,如 Parallel WaveNet<sup>[27]</sup>。

• LPCNet: LPCNet 于 2019 年提出,是一种高效且实时的神经网络声码器。 其以 WaveRNN 声码器<sup>[28]</sup> 为基础,结合了深度学习和数字信号处理,显式 加入了线性预测系数 (Linear Prediction Coefficients, LPC) 来降低神经网络 建模的复杂度。LPCNet 可以分为两个子网络,帧级别网络和采样点级别网 络,以及一个计算 LPC 的模块。在生成过程中,帧级别网络对输入的每一 帧声学特征计算条件向量,LPC 模块从声学特征中计算 LPC,两个特征在 帧内保持不变。采样点级别网络根据一帧对应的特征,以自回归的方式预 测样本点。相比 WaveNet, LPCNet 的计算复杂度很低,可以高效地实现实 时合成。

# 2.3 特征对齐

在实际情况中,两个不同的说话人说同一句话时时间长短往往是不一样的,因此就需要对两段对应的特征序列进行对齐操作,将它们统一成相同的长度。由于特征对齐的情况大多在平行语料的语音转换中出现,因此本文主要说明平行语料语音转换中的特征对齐。

对于长度不一致的问题,比较容易想到的方法是通过拉伸的方法将较短的音频拉长到与较长音频长度相同,但是两段语音之间的长度差距并不是等比例的,即对于内容中的一些字词,原始说话人说的较快,而对于另外一些字词,目标说话人则说的较快。等比例的拉伸并不能做到较好的帧级别对应。除此之外,最常用的特征对齐方法就是动态时间规整 (Dynamic Time Warpingm, DTW) 算法。该算法通过动态规划来计算两个特征序列之间的最短距离,同时保存该最短距离所对应的路径。如图 2-5所示,上下两条粗线为两个特征序列,中间的虚线代表特征的一一对应关系,对应关系的序列就是两个序列的最短路径。DTW 通过计算两个序




图 2-5 DTW 算法序列对齐示意图

Figure 2–5 Schematic diagram of DTW alignment algorithm

列之间的最短路径来实现对齐。然而 DTW 算法仍有较大的对齐误差,尤其是对于差别较大的特征片段,而较大的对齐误差对转换效果的影响非常大。因此研究人员将更多的注意力放在了无需对齐的方法上。非平行语音转换方法大多不需要对齐操作,这也是其优势之一。

# 2.4 声学特征转换方法

声学特征转换是语音转换中最重要的部分,也是当前主要的研究对象。声学特征的转换通常需要一个转换模型来完成,转换模型输入原始声学特征序列,输出转换后的目标声学特征。本节主要介绍平行语料下的特征转换方法,非平行语料下的特征转换方法将在下一章中详细介绍。

#### 2.4.1 混合高斯模型法

混合高斯模型法是在深度学习方法之前使用最为广泛的方法之一。该方法使用混合高斯模型 (Gaussian Mixture Model, GMM) 对原始说话人声学特征建模,并通过转换函数将原始特征转为对应的目标特征。设原始特征向量为 x,用 GMM 模型表示其概率分布为

$$p(\mathbf{x}) = \sum_{i=1}^{m} \alpha_i N(\mathbf{x}; \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)$$
 (2-4)

其中  $N(\mathbf{x}; \boldsymbol{\mu}, \boldsymbol{\Sigma})$  代表均值为  $\boldsymbol{\mu}$ , 协方差矩阵为  $\boldsymbol{\Sigma}$  的  $\boldsymbol{p}$  维高斯分布, 可以表示

为

$$N(\mathbf{x}; \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{p/2}} |\boldsymbol{\Sigma}|^{-1/2} exp \left[ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right]$$
(2-5)

公式中  $\alpha_i$  是归一化的正标量权重 ( $\sum_{i=1}^m \alpha_i = 1$  and  $\alpha_i \geq 0$ )。在 GMM 的语音转换方法中,一个基本假设是声学特征的向量之间是相互独立的,即 t 时刻的目标特征向量  $\mathbf{y}_t$  只依赖与同一时刻的原始特征向量  $\mathbf{x}_t$ 。而 GMM 的一个优点是可以在不同的分布分量中进行软分类,在某种程度上,每一个类别可以代表不同的音素,或其他音素相关的声学分类。给定观测向量  $\mathbf{x}_t$ ,判断其属于 GMM 中一个声学类别  $C_i$  的条件概率可以表示为

$$P(C_i|\mathbf{x}) = \frac{\alpha_i N(\mathbf{x}; \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)}{\sum_{j=1}^m N(\mathbf{x}; \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)}$$
(2-6)

GMM 的参数可以通过期望最大化 (Expectation-Maximization, EM) 算法来估计。用 GMM 模型在原始声学特征上建模后,则需要一个转换函数来将输入的原始特征向量转变为对应的目标特征向量,可以定义转换函数如下

$$\mathcal{F}(\mathbf{x}_t) = \sum_{i=1}^{m} P(C_i | \mathbf{x}_t) \left[ \mathbf{v}_i + \boldsymbol{\Gamma}_i \boldsymbol{\Sigma}_i^{-1} (\mathbf{x}_t - \boldsymbol{\mu}_i) \right]$$
 (2-7)

转换函数的参数只要是  $\mathbf{v}_i$  和  $\mathbf{\Gamma}_i$ ,输入其中  $\mathbf{v}_i$  表示目标特征的期望均值, $\mathbf{\Gamma}_i$  表示原始特征与目标特征的协方差矩阵。这些参数通过最小化转换的均方误差来估计。误差可表示为

$$\epsilon = \sum_{t=1}^{n} \left| \left| \mathbf{y}_{t} - \mathcal{F}(\mathbf{x}_{t}) \right| \right|^{2}$$
 (2-8)

该方法可以通过只对原始特征进行 GMM 建模来实现逐帧的语音转换。在此之后,一些基于 GMM 对目标特征建模的方法也被提出<sup>[10]</sup>。但是混合高斯法建立在不同帧之间相互独立的假设之上,只能实现逐帧转换,这是限制 GMM 转换性能的一个主要因素。

#### 2.4.2 码本映射法

码本映射法 (Codebook Mapping) 的历史比混合高斯法更为悠久,是最早出现的语音转换方法之一。直观的码本映射法即是将原始和目标特征合并在一起,训练一个大的码本。在转换时,原始特征先通过码本得到码本编号,与该编号最接近

的目标特征即是转换特征。之后研究人员在码本映射法中加入了矢量量化 (Vector Quantization, VQ) 的方法。该方法先对原始和目标特征通过 VQ 各自生成一个码本。同时对平行特征序列用 DTW 算法进行对齐,根据特征之间的对应关系生成直方图。对于原始说话人每个码本向量的直方图,通过加权平均得到该码本向量对应的码本映射。在转换阶段,对原始特征的每一个特征向量,先通过原始说话人的码本编码得到量化向量,再用该向量对应的码本映射得到转换特征。

码本映射法的基本思想简单直接,但也有比较明显的缺陷。首先逐帧转换对 转换语音的连贯性有很大的影响,其次对声学特征离散化表示进行聚类会损失较 多的声学信息,导致转换单一,自然度较差,以及线性平均造成的严重过平滑问 题。对于这些缺陷,研究人员也提出一些改进措施比如码本词的线性加权组合法、 分层的码本映射法和局部线性转换法等等。

### 2.4.3 频率弯折法

频率弯折法与之前介绍的语音转换方法不同,它是基于规则的语音转换方法。 频率弯折法一般是通过频域中较为突出的区域特征来建立原始与目标的映射关 系 (如共振峰的中心频率)。比较典型的频率弯折法是基于声道长度归一化 (Vocal Tract Length Normalization, VTLN) 的语音转换方法。

在基于 VTLN 的方法中,最优频率弯折函数  $w(f,\theta)$  的参数可以定义为

$$\theta = \arg\min_{\theta} \int_{w=0}^{\pi} |Y(f) - X(w(f, \theta))|^2 dw$$
 (2-9)

其中 X(f) 和 Y(f) 分别代表原始和目标频谱。一般频谱弯折函数中只有一个 参数  $\theta$ ,常见的弯折函数有二次函数

$$w_{\theta}(f) = f + \theta \left[ \frac{f}{\pi} - \left(\frac{w}{\pi}\right)^2 \right]$$
 (2-10)

以及双线性函数

$$w_{\theta}(f) = \frac{f - \alpha}{1 - \alpha f} \tag{2-11}$$

频率弯折法通过对频谱中最显著的部分进行连续函数变换来实现语音转换, 这样做的好处是可以在保留频谱中的大部分信息的前提下,保证频谱的连贯性。 因此频率弯折法往往可以得到比较好的音质,但是由于频谱中的说话人信息并不 只包含在最显著的特征中,同时也存在于其他特征上(如共振峰带宽)。因此频率 弯折法的主要缺陷在于转换音频的说话人相似度较低。

#### 2.4.4 神经网络法

神经网络 (Neural Networks, NN) 是一种从生物学中受到启发的建模方式。神经网络的发展历史较早,但早期多专注于理论阶段和复杂度相对较小的模型实验,因此也提出了很多模型结构但难以验证。随着大数据和计算机硬件的飞速发展,神经网络模型的参数量可以随着训练数据量的增多和计算速度的变快而不断地增加,从而可以实现更为复杂的网络结构和建模任务,我们称之为深度学习。由于神经网络具有强大的建模能力,使得其在很多建模任务上相较传统的机器学习算法都取得了突破性的进展。如今,神经网络已经在很多领域得到了广泛的应用,如计算机视觉,自然语言处理和智能语音等。




图 2-6 多层感知机结构图

Figure 2-6 Architecture of the Multilayer Perceptrons

最初的神经网络由多层感知机发展而来 (Multi-Layer Perceptrons, MLP)。如图 2-6, MLP 由一个输入层,多个隐藏层,一个输出层组成。每一层都包含有多个神经元,每个神经元都可以对输入做加权线性变换,并将结果输出。经过逐层的前向传播,MLP 在输出层输出模型结果。在训练时,MLP 的输出会根据对应的标签计算误差,并使用反向传播 (Back Propagation, BP) 算法计算梯度,并根据每个参数的梯度更新模型。从而使得模型可以不断的拟合训练数据。在数据量较大的情况下,神经网络具有较强的泛化能力,在测试集上的性能往往要好于传统方法。在深度学习时代,神经网络的种类层出不穷,其中较为著名的包括深度神经网

络 (Deep Neural Networks, DNN),循环神经网络 (Recurrent Neural Networks, RNN), 卷积神经网络 (Convolutional Neural Network, CNN)等,其中每个网络也有较多的变种。

基于人工神经网络 (Artificial Neural Networks, ANN) 的语音转换方法在 2009 年被提出<sup>[67]</sup>。作者用 4 层的神经网络学习原始特征到目标特征的映射关系,相邻两层之间采用全连接的形式。在训练阶段,首先从原始和目标音频中分析,25 维的梅尔倒谱系数和 1 维基频特征; 然后用 DTW 算法对平行特征序列进行对齐,模型的输入是原始特征,标签是目标特征; 最后使用反向传播算法对模型进行训练。论文中的实验结果说明了基于神经网络的语音转换方法在主观实验和客观实验上都普遍好于基于 GMM 模型的语音转换方法。该工作证实了神经网络在语音转换任务上的可行性。之后针对类 ANN 网络的语音转换改进方法也不断被提出。




图 2-7 长短时记忆网络结构图

Figure 2–7 Architecture of the Long Short Term Memory

如前文所述,很多方法都存在声学特征帧相互独立的假设,然而这个假设与常识有所矛盾,语音作为一个时序序列,距离越近的时刻往往相关性就越大。即使有些方法也被提出来弥补这方面的缺陷,如加入动态特征,当前方法仍然没有很好的贴合时间序列的特性来实现更好的转换性能。在 2015 年,研究人员提出了基于深度双向长短时记忆网络 (Deep Bidirectional Long Short Term memory,DBLSTM) 的语音转换方法<sup>[45]</sup>。该方法创新点主要为使用了包含 DNN 和双向 LSTM 的转换模型。LSTM 是 RNN 的一个变种,针对 RNN 对长时信息的建模能力较差,LSTM 在 RNN 的单元 (cell) 中加入了三个门控机制,分别为输入门,遗忘门和输出门。单元的状态值代表历史时刻的信息,其在网络的序列计算中不断更新。如图 2–7所示,三个门控会通过 sigmoid 函数输出 0 到 1 之间的值,输入门表示当前时刻输入加入单元状态值的比例,遗忘门表示当前时刻要从单元状态值中遗忘多少信息,输出门表示从更新后的单元状态值中输出多少比例到下一单元。设输入特征序列  $\mathbf{x} = \{x_1, x_2, ..., x_T\}$ ,当前隐藏层的激活值为  $\mathbf{h} = \{h_1, h_2, ..., h_T\}$ ,LSTM 单元在 t

时刻的计算过程可以用如下公式表示

$$i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i) \tag{2-12}$$

$$f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f)$$
 (2-13)

$$c_t = f_t c_{t-1} + i_t tanh(W_c x_t + U_c h_{t-1} + b_c)$$
 (2-14)

$$o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o) \tag{2-15}$$

$$h_t = o_t tanh(c_t) (2-16)$$

其中 $\sigma$ 表示 sigmoid 激活函数,W和U为可学习的矩阵参数,i,f和o分别代表输入门,遗忘门和输出门,c表示单元状态。双向网络在单向网络的基础上添加了额外一层,该层以由后向前的时间顺序传播,两个相反方向的 LSTM 层输入同一个特征序列,并将输出的隐层序列拼接起来,形成最终的输出。在<sup>[45]</sup>中,转换模型由 6层 BLSTM 网络组成,并使用基于时间的反向传播算法 (Back-Propagation Through Time,BPTT) 训练模型。实验表明,基于 DBLSTM 的转换模型明显好于基于 DNN 的方法。对比加入动态特征的 DNN 方法,DBLSTM 模型在平均意见分 (Mean Opinion Score, MOS) 上高出 0.5分。

上面所述方法都有效促进了语音转换音质的提升,但这些方法都会受到特征对齐准确度的限制。如前文所述,特征对齐的准确度对语音转换有很大的影响,目前所用到的特征对齐方法普遍还是基于 DTW 算法,而韵律差别较大的特征序列往往会使 DTW 算法的准确度急剧下降。因此,基于序列到序列和注意力机制 (Sequence-to-Sequence Attention) 的语音转换模型于 2019 年提出<sup>[49]</sup>。序列到序列和注意力机制模型是序列建模中非常著名的模型,它可以实现不受输入长度约束的不定长输出。序列到序列和注意力机制模型通常由三个模块构成:编码器,注意力模块和解码器。其中编码器对输入的特征序列进行变换,将其转换成相同长度的抽象特征序列;解码器采用自回归的计算方式,输入上一时刻的输出,和当前时刻注意力机制计算的注意力向量进行拼接,再去预测当前时刻的输出;注意力机制是一种序列相似度的对齐机制,其输出向量的物理意义是指与当前解码器输入向量 (Query, Q) 最相似的编码器输入向量 (Key, K) 的特征值信息 (Value, V)。公式表示如下

$$\mathbf{c}_t = \sum_{i=1}^n \alpha_{t,i} \mathbf{h}_i \tag{2-17}$$

其中  $\alpha_{t,i}$  表示 t 时刻输入与第 i 个编码器输入向量的匹配程度。 $\mathbf{h}_i$  代表第 i 个

输入向量。α的计算方法如下

$$\alpha_{t,i} = \frac{exp(score(\mathbf{s}_{t-1}, \mathbf{h}_i))}{\sum_{i'=1}^{n} exp(score(\mathbf{s}_{t-1}, \mathbf{h}_{i'}))}$$
(2–18)

s是指编码器输入向量。score 的计算方法有很多种,如余弦法,点乘法,基于位置的方法等。注意力机制在解码器解码时向其提供输入序列的局部信息,以使解码结果与输入的对应位置保持一直,另一方面,注意力机制可以完成更为复杂的对齐操作,可以实现相比 DTW 更为准确的对齐路径,从而提升转换性能。除此之外,论文中也额外添加了一个编码器和一个解码器,通过对原始特征序列和目标特征序列进行重构,来尽可能在转换过程中保留特征中的语义信息。实验证明,该方法的转换语音在自然度和相似度上都要好于基于 GMM 的语音转换方法,另外该方法也好于基于 LSTM 的语音合成方法。这也是目前在平行语音转换任务上转换音质最好的方法之一。

## 2.5 韵律转换

韵律一般是指语音的发音节奏,语速和表现力等,与说话人的说话风格有很大的关系,准确的韵律转换可以使转换语音更接近目标说话人。与韵律相关的特征主要有基频和时长,下面将对这两种特征的主要转换方法做以说明。

#### 2.5.1 基频转换

基频 (Fundamental Frequency, F0) 代表着语音当中的最低频率,由于基频在人耳的感知中具有最大的响度,因此基频常与语音的音调等价。基频的转换是十分必要的,尤其对于跨性别语音转换,男性的基频分布与女性的基频分布往往差别较大,此时基频的转换效果会直接影响转换语音的相似度。

传统的基频转换方法通常使用均值方差归一化的线性转换。该方法非常简单直接,首先从原始和目标训练数据中提取基频序列;然后分别计算原始基频序列和目标基频序列的均值 ( $\mu_s$ ,  $\mu_t$ ) 和方差 ( $\sigma_s$ , $\sigma_t$ );在转换阶段,对原始测试基频用原始说话人的均值方差先做归一化,再用目标说话人的方差均值对其做逆归一化。转换过程可用公式表示如下

$$F_0^t = (F_0^s - \mu_s) \frac{\sigma_t}{\sigma_s} + \mu_t \tag{2-19}$$

其中  $F_0^s$  和  $F_0^t$  分别代表原始基频和转换目标基频。在乐理中,基频在对数域会呈现等差增长,即音高频率在对数域是平均分布的,且在[36] 中,基频在对数域

比在线性域能够更好地被正态分布拟合。因此在实际操作中更倾向于以对数基频为线性转换的对象。

然而线性变换也存在明显的缺陷,该方法只能改变基频的分布,而不能改变基频的变化趋势。在<sup>[68]</sup>中,作者在平行语料的语音转换任务中,使用梅尔频谱特征代替传统的数字信号声码器分析特征(梅尔倒谱系数,基频,非周期成分),直接用转换模型学习梅尔频谱中基频信息的转换。经过实验验证,使用模型学习基频的隐式转换可以获得更接近目标基频轨迹的转换语音。

### 2.5.2 时长转换

时长转换的常用方法与基频转换类似,也是使用线性转换的方法改变语速,即对一整句话进行固定比例的拉伸操作来改变时长,如线性插值或样条插值。除此之外一些基于音素的韵律转换方法也被提出<sup>[69]</sup>。如前文所述,在<sup>[49]</sup>中,序列到序列的建模方式可以有效实现不等长序列的映射关系学习,同时也可以做到不定长序列的生成,该模型的解码器通过在每个时间步判断停止令牌(stop token)来决定是否需要停止解码。但是,时长转换由于评价指标较难定义,且对说话人相似度的影响较小,目前研究的主要重心仍集中在频谱转换上。

# 2.6 本章小结

本章主要介绍语音转换系统的典型框架及其主要部分,包括语音分析和合成方法,特征对齐,频谱转换方法和韵律转换方法。本章首先对语音转换系统,评价指标及常用特征进行了回顾;然后介绍了语音转换系统中每个部分的主流技术及最新进展,并对其优势和不足进行了分析。作为语音转换中最重要的部分,本文对常见的几种平行语料的频谱转换方法进行了详细的介绍。

# 第三章 非平行语料的语音转换

## 3.1 引言

上文已经介绍了语音转换的典型框架及其各部分的主要技术,其中对于频谱转换方法主要介绍了平行语料下的语音转换方法如混合高斯模型法,码本映射法,频率弯折法和神经网络法。随着语音转换技术的不断发展,目前在平行语料下已经可以得到比较自然的转换声音了,然而在语音转换的实际应用中,平行语料的获取往往需要搜集大量网络数据并从中匹配原始和目标的平行数据对,甚至原始或目标说话人亲自录制平行语料,同时还需要尽可能保证训练数据与实际测试数据的环境条件相同,这些都大大增加了语音转换模型的构造成本。相比平行语料而言,非平行语料的获取成本会低很多,对于知名度较高的说话人,往往可以搜集到大量非平行语料数据。因此,基于非平行语料的语音转换方法更符合语音转换任务的实际需求。为了与实际应用相结合,研究人员在近两年提出了许多能够实现非平行语料的频谱转换方法。如今,非平行语料正在成为语音转换的研究热点和难点。

本章将主要介绍非平行语音转换及当前常见的频谱转换方法,包括基于音素后验概率图的方法,对抗训练法以及变分自编码器法。之后将重点介绍基于 CycleGAN 的语音转换方法,该方法是非平行语料的语音转换方法中使用较为广泛的一种,也与本文的研究工作密切相关。

# 3.2 非平行语料语音转换概述

非平行语料的语音转换 (Non-parallel Voice Conversion) 是指在原始和目标说话人的训练数据不包含相同的文本内容的条件下,构造语音转换模型。在语音分析合成方法和韵律转换方法上,两者没有本质区别。然而不同于平行语料的语音转换,非平行语料的语音转换属于无监督任务,对于原始说话人的每一句话,并不存在对应的标签,因此模型需要通过额外模型的帮助或特殊的训练方法来实现从两个说话人的特征中学习说话人信息并转换。非平行语料语音转换通常不需要特征对齐的步骤,两者的主要差别在频谱转换方法中。早期的非平行语料语音转换方法以自适应的方法为主<sup>[70,71]</sup>。如最早于 2004 年提出<sup>[70]</sup>,作者在基于 GMM 的语音转换方法上,先使用已有的说话人平行语料预训练一个转换模型,然后再将非平行语料的原始和目标说话人分别对转换模型做说话人自适应,从而实现非平行

语料的语音转换。另一种可行的办法是使用语音合成中的单元选择 (Unit Selection) 技术<sup>[31]</sup>,从目标特征中选择与原始特征最匹配的特征帧,来实现无监督的语音转换。为了保证声学特征的连续性,当前帧的值由匹配目标帧和上一帧加权决定。

随着近两年非平行语料的语音转换关注度增加,研究人员基于神经网络技术提出了一些更为有效的解决方案。如音素后验概率图法,对抗训练法和变分自编码器法。其中,基于循环一致性生成对抗网络 (CycleGAN) 的语音转换方法在不需要任何额外数据和模型的前提下,实现了与平行语料转换方法接近的转换性能。下文将详细介绍这些方法。

## 3.3 常见特征转换方法

#### 3.3.1 音素后验概率图法

音素后验概率图法 (Phonetic PosteriorGrams, PPGs) 最早于 2016 年提出,是一种可以实现任意原始说话人到特定目标说话人 (Any-to-One) 的语音转换方法<sup>[52]</sup>。该方法的核心思想是使用一个说话人无关特征作为中间特征,来作为原始和目标声学特征之间的媒介。通过说话人无关特征的提取器可以从任意原始说话人的语音中提取中间特征,然后只需要训练一个从说话人无关特征到目标说话人声学特征之间的映射模型便可以实现语音转换。最直观的说话人无关特征即是文本特征,因此文章中使用每一帧对应的音素后验概率图作为中间特征,并用语音识别系统 (Automatic Speech Recognition, ASR) 作为该特征的提取器。

如图 3-1所示,基于 PPG 的语音转换方法可以分为三个模块:训练模块一,训练模块二和转换模块。在训练模块一中,使用标准的语音识别数据集训练说话人无关的语音识别系统,这里需要用到语音识别中的声学特征如梅尔频率倒谱系数 (MFCC) 或滤波器组 (Filter Bank, FBank)。语音识别模型的训练可以依靠 Kaldi 开源工具<sup>[72]</sup> 完成。在训练模块二中,首先对目标说话人的训练数据分别提取 ASR 声学特征和 VC 声学特征,两个特征帧数需要保持一致。之后语音识别模型从 ASR 特征中预测每一帧对应的 PPG 特征,并用基于神经网络的转换模型学习从 PPG 到 VC 声学特征的映射关系。在测试阶段,从原始音频中提取 ASR 特征,再使用 ASR 模型和转换模型将其依次转换为 PPG 特征和 VC 特征,最后结合线性变换的基频和非周期信号,用 WORLD 声码器合成转换语音。

当前方法在实践中存在一个主要问题,由于该方法可以实现任意原始说话人的语音转换,因此在训练阶段并没有原始说话人的训练数据,而在测试时却需要对基频进行线性变换。可能的解决方法是直接以当前句子为单位,将该句的基频分布作为原始说话人的分布。2018年作者使用 Griffin Lim(GL) 声码器来合成声音,




图 3-1 音素后验概率图语音转换方法示意图

Figure 3–1 Schematic diagram of the Phonetic PosteriorGrams Voice Conversion method

即直接从 PPG 中预测包含基频信息的频谱。为此作者在此基础上提出两个改进,一是将 PPG 与原始对数基频序列拼接到一起作为转换模型的输入,加入原始基频信息可以帮助模型学习到频谱中基频的隐式表达,从而转换出更为自然的基频轨迹;二是对于频谱的较高维度,建模难度较大,因此作者将频谱分为多个有重合的子带,每个子带使用一个单独的转换模型建模。测试时每个转换模型输出对应的子带频谱后,对这些子带频谱加海明窗后拼接在一起,得到转换频谱。

随着 WaveNet 的提出,基于 PPG 的方法在 WaveNet 声码器下也做出了改进。对于语音转换和语音合成来说,模型生成的声学特征和真实特征往往有一定差距,而神经网络声码器的训练特征往往都是真实特征,因此在测试时生成的声学特征往往会导致转换语音音质的明显下降。基于此问题,作者提出在基本框架上去除声学特征的约束,直接 PPG 作为 WaveNet 的条件特征。即将转换模型改为条件网络,和声码器共同训练。其中转换网络由两个包含自注意力和 BLSTM 的模块组成。

### 3.3.2 对抗训练法

对抗训练法主要是指由循环一致性生成对抗网络 (Cycle-consistency Generative Adversarial Networks, CycleGAN) 为代表的一系列工作。基于 CycleGAN 的语音转换方法于 2017 年提出,该方法以对偶学习为基础,包含两个互为对偶的生成模型,两个对偶模型相互串联,可以得到两个循环来对特征进行重建,同时加入判别器对重建的中间结果进行约束,实现无监督训练。在测试阶段,只需要四个模型中的其中一个生成器作为转换模型,转换流程与标准的语音转换方法没有本质差别。下一节将详细介绍 CycleGAN 的内部结构和训练机制。

针对多说话人到多说话人 (Many-to-Many) 的语音转换,作者于 2018 年提出了基于 StarGAN 的语音转换方法。该方法可以实现同一个模型对原始说话人集合和目标说话人集合中的任意说话人对进行语音转换。StarGAN 由一个生成器 G,一个判别器 D 和一个分类器 D 组成。在训练阶段,三个模型同时训练,受三个损失函数监督,分别是对抗损失,领域分类损失和循环一致性损失。设输入特征序列为  $\mathbf{x} \in \mathbb{R}^{Q \times N}$ ,目标属性标签为 c,对抗损失可以公式表示为

$$L_{adv}^{D}(D) = -\mathbb{E}_{c \sim p(c), \mathbf{y} \sim p(\mathbf{y}|c)} \left[ log D(\mathbf{y}, c) \right]$$
(3-1)

$$-\mathbb{E}_{\mathbf{x} \sim p(\mathbf{x}), c \sim p(c)} \left[ log(1 - D(G(\mathbf{x}, c), c)) \right]$$
(3-2)

$$L_{adv}^G(G) = -\mathbb{E}_{\mathbf{x} \sim p(\mathbf{x}), c \sim p(c)} \left[ log D(G(\mathbf{x}, c), c) \right] \tag{3-3}$$

其中  $\mathbf{y} \sim p(\mathbf{y}|\mathbf{c})$  表示已知类  $\mathbf{c}$  后的真实样本集合。对于生成器和对抗器分别有不同的对抗损失,生成器尽可能生成足够真实的类  $\mathbf{c}$  样本来欺骗判别器,另一方面判别器尽可能准确地区分真实类  $\mathbf{c}$  样本和生成器生成出来的样本,判别损失可以通过对抗训练不断优化生成器和判别器,它可以帮助生成器生成接近目标分布的特征。领域分类损失可以表示为

$$L_{cls}^{C}(C) = -\mathbb{E}_{c \sim p(c), \mathbf{y} \sim p(\mathbf{y}|c)} \left[ log p_{C}(c|\mathbf{y}) \right]$$
 (3-4)

$$L_{cls}^{G}(G) = -\mathbb{E}_{\mathbf{x} \sim p(\mathbf{x}), c \sim p(c)} \left[ log p_{C}(c|G(\mathbf{x}, c)) \right]$$
(3-5)

(3-6)

其中  $p_C(c|\mathbf{y})$  表示特征序列  $\mathbf{y}$  属于类 c 的概率。由公式可知,在训练阶段,分类器要尽可能准确识别真实特征所属的类别。而生成器要尽可能生成让分类器分

类正确的类 c 样本。循环一致性损失如下所示

$$L_{cyc}(G) = \mathbb{E}_{c' \sim p(c), \mathbf{x} \sim p(\mathbf{x}|c'), c \sim p(c)} \left[ \left| \left| G(\mathbf{x}, c), c' \right| - \mathbf{x} \right| \right|_{\rho} \right]$$
(3-7)

其中c和c'代表两个不同的类别, $\rho$ 是一个正整数。另外为了在转换过程中 尽可能保留语义信息,会额外添加一个身份损失,表示如下

$$L_{id}(G) = \mathbb{E}_{c' \sim p(c), \mathbf{x} \sim p(\mathbf{x}|c')} \left[ \left| \left| G(\mathbf{x}, c') - \mathbf{x} \right| \right|_{\rho} \right]$$
(3-8)

身份损失通常在训练的初始阶段添加,可以有效缩小模型参数空间,加速收敛。为了进一步提升 StarGAN-VC 的性能,作者于 2019 年提出了 StarGAN-VC2<sup>[60]</sup>。文中首先对模型的输入添加了额外的原始领域标签,使得模型的输入是原始-目标标签对,而不是只有目标标签; 其次作者使用了基于调制的加入条件特征方法,传统的加入条件的方法通常是将条件向量与网络层的输入进行拼接或相加,但是这样做的不足是只改变了当前特征的一个维度,模型需要靠这一个维度来输出截然不同的结果,因此作者将条件向量变为该类别所对应的均值,方差。网络的条件是有限的,对于每一组条件,都对应两个值,分别代表均值和方差。添加条件时,先对当前特征进行归一化,然后再通过条件变量转变为另一分布,表示如下

$$CIN(\mathbf{f}; c') = \gamma_{c'}(\frac{\mathbf{f} - \mu(\mathbf{f})}{\sigma(\mathbf{f})}) + \beta_{c'}$$
(3-9)

其中  $\mathbf{f}$  表示特征矩阵, $\mu$  和  $\sigma$  分别代表特征矩阵的均值和方差, $\beta$  和  $\gamma$  分别表示条件对应的均值和方差。

#### 3.3.3 变分自编码器法




图 3-2 变分自编码器语音转换方法示意图

Figure 3-2 Schematic diagram of the VAE Voice Conversion method

基于变分自编码器 (Variational AutoEncoder, VAE) 的语音转换方法于 2016 年 被提出。VAE 同生成对抗模型类似,也是生成模型的一种。如图 3-2所示, VAE

可以分为编码器  $\phi$  和解码器  $\theta$  两个模型,其中编码器将输入的声学特征  $\mathbf{x}_n$  转换为说话人无关的隐变量  $\mathbf{z}_n$ :

$$\mathbf{z}_n = f_{\phi}(\mathbf{x}_n) \tag{3-10}$$

此时隐变量只包含说话人无关的信息,例如音素,韵律等。之后,用解码器将隐变量恢复为最初的输入  $\mathbf{x}_n$ ,为此,需要额外添加说话人信息变量  $\mathbf{y}_n$ 。解码器以隐变量和说话人信息拼接之后的结果作为输入,即

$$\hat{\mathbf{x}}_n = f_{\theta}(\mathbf{z}_n, \mathbf{y}_n) \tag{3-11}$$

基于 VAE 的语音转换方法基于两个假设:一是说话人信息和说话人无关信息可以从一帧声学特征向量中解耦出来;二是解码器可以通过混合这两个信息来合成一个声学特征向量。模型的最终目标函数可以表示为

$$\hat{L}(\theta, \phi, x_n) = -D_{KL}(q_{\phi}(\hat{z}_n | x_n) | | p(z_n)) + log p_{\theta}(x_n | \hat{z}_n, y_n)$$
(3-12)

在转换过程中,编码器首先将输入帧转变为隐向量,然后解码器输入隐向量和目标说话人向量来输出转换特征帧。

# 3.4 基于 CycleGAN 的语音转换方法

本文所做的语音转换工作主要基于 CycleGAN 的语音转换方法,本节将先简要介绍该方法涉及到的基本概念如对偶学习,生成对抗网络等,之后对 CycleGAN 的原理及其在语音转换上的优化进行详细说明。




图 3-3 标准 CycleGAN 示意图

Figure 3-3 Schematic diagram of the standard CycleGAN

#### 3.4.1 对偶学习概述

对偶学习 (Dual Learning) 的概念最早于 2016 年提出<sup>[73]</sup>。以神经网络为代表的深度学习技术近两年在许多领域内都取得了巨大的成功,其中一个重要的因素就是大数据,尤其是大规模的经过标注的数据。例如在语音合成中,神经网络通常需要上万句带有标注的音频样本来学习文本到声学特征之间的关系,这些数据需要大量人工对其进行标注,校对等工作,极大增加了一个模型的构建成本。这个问题在机器翻译领域尤为突出,在机器翻译中,会用到上千万的双语句对进行训练,这对数据的收集和标注都提出了很大的挑战。深度学习技术的广泛性与其对大规模标注数据的依赖性有很大的关系。为了解决这个问题,研究人员提出了一种新的学习范式,即对偶学习。

可以发现,很多深度学习的任务都可以衍生出一个对偶任务,如机器翻译的中译英和英译中,语音转换的原始说话人转目标说话人和目标说话人转原始说话人,甚至语音识别和语音合成。这些互为对偶的深度学习任务可以形成一个闭环,使从没有标注的数据中学习模型成为可能。对偶学习最重要的一点是,对于一个主任务,其对偶任务可以给其反馈,反过来主任务也可以给对偶任务以反馈,从而实现两个任务相互反馈,相互学习。

实际上对偶学习与强化学习的学习过程较为相似。在强化学习中,并没有标注样本来告诉模型在某个状态执行某个动作是正确的,模型只有通过使用策略在某个状态下执行不同的动作,观测该动作带来的回报,从而改善策略。在对偶学习中,两个对偶任务就是策略,模型输入就是状态,两次模型的输出就是动作,而重建误差就是动作带来的回报。

以中英机器翻译为例,已有预训练或未训练的英译中模型 f 和中译英模型 g,给定一个英文句子 x,首先用英译中模型 f 将该句翻译成中文 y',然后将该中文句子 y' 发送给中译英模型 g。中译英模型 g 并不知道正确的翻译是什么,但可以知道这个中文句子语法是否正确,是否符合中文语言模型,这些信息都可以帮助中译英模型 g 判断英译中模型 f 是否做的好。然后中译英模型 g 翻译成英文句子 x',通过比较 x 和 x' 是否相似,就可以判断两个模型 f 和 g 做的是不是足够好,尽管输入 x 是一个没有标注的句子。同理,也可以输入中文句子,使其分别通过中译英模型 g 和英译中模型 f ,来实现重建。因此,通过这样的一个对偶游戏的过程,就能够从没有标注的数据上获得反馈,从而提高模型性能。

对偶学习同样可以应用在语音转换中,对于语音转换而言,原始说话人和目标说话人可以互相调换,来得到对应的对偶任务。为了训练从说话人 A 到说话人 B 的语音转换模型 G, 需要同时学习转换模型  $G_{A\to B}$  和  $G_{B\to A}$ 。分别输入两个说

话人的原始特征,通过两个模型对原始特征进行重构,将重构误差作为回报帮助两个模型训练。但是仅有重构误差对于语音转换的对偶学习来说还是不够的,因为两个模型很容易都训练成将输入原样输出来使重构误差最小,为了解决这个问题,需要在每次循环中对第一个模型的输出加入约束,强制其输出符合目标说话人的特征分布。

#### 3.4.2 生成对抗网络简介

生成对抗网络 (Generative Adversarial Networks, GAN) 由 Ian Goodfellow 等人于 2014 年提出<sup>[74]</sup>。迄今为止 GAN 已经在许多生成式任务中实现了非常好的效果,如图像生成,自然语言生成和音乐声称等。该模型从一个游戏理论中获得启发:两个模型,一个生成器 (Generator),一个判别器 (Discriminator),在互相竞争的过程中彼此越来越强大。然而,GAN 的训练是较为困难的,研究人员在训练过程中经常遇到不稳定和模型不收敛的问题。

GAN 包含两个模型: 判别器 D 对输入样本进行判断, 并输出该样本属于真实数据集的概率, 判别器像一个裁判, 其优化目标是对真实样本尽可能高的概率值, 同时对合成样本较低的概率值。生成器 G 输入噪声变量 z, 输出合成样本, 生成去的训练目标是尽可能生成接近真实数据分布的合成样本, 以至于可以欺骗判别器, 使其给出较高的概率值。在训练过程中, 两个模型在这个零和游戏中互相对抗, 并不断提升彼此的能力。

一方面, 判别器 D 确保在真实数据上足够准确, 通过最大化  $\mathbb{E}_{x\sim p_r(x)}[log D(x)]$ , 同时,输入一个假的样本 G(z),  $z\sim p_z(z)$ , 判别器期望输出其概率 D(G(z)) 尽可能接近 0 通过最大化  $\mathbb{E}_{z\sim p_z(z)}[log(1-D(G(z)))]$ 。在另一方面,生成器希望提升判别器对其生成的样本的概率值通过最小化  $\mathbb{E}_{z\sim p_z(z)}[log(1-D(G(z)))]$ 。将两个目标函数合并,可以得到需要优化的损失函数

$$\min_{G} \max_{D} L(D, G) = \mathbb{E}_{x \sim p_r(x)} [log D(x)] + \mathbb{E}_{z \sim p_z(z)} [log (1 - D(G(z)))]$$
 (3-13)

其中等号右边的第一项对生成器 G 训练时没有影响。通过对损失函数在所有 x 上求导,可以得到对于判别器而言,其使损失函数最低的最优概率值为 0.5,整个 损失函数的全局最优值为 -2log2。GAN 的发展至今已经演变出很多种类,包括加入条件的条件 GAN,使用最小二乘法的 LSGAN,以及引入对偶学习的 CycleGAN,StarGAN 等。

### 3.4.3 CycleGAN 网络的训练

CycleGAN 网络包含四个模型,两个生成器  $(G_{X\to Y},G_{Y\to X})$  和两个判别器  $(D_X,D_Y)$ , X 和 Y 分别代表原始域和目标域。四个模型通过两个个损失函数来实现无监督的训练: 对抗损失 (Adversarial Loss) 和重构损失 (Reconstruct Loss)。其中对抗损失用来衡量转换的目标特征和真实的目标特征之间的区分程度。判别器通过最大化对抗损失来尽可能区分转换特征和真实特征,同时生成器通过最小化对抗损失来尽可能生成接近真实的转换特征,从而欺骗判别器。其训练方式与生成对抗网络类似,生成器和判别器交替训练更新,训练生成器时判别器只回传梯度,不更新梯度。对抗损失表示如下

$$L_{adv}(G_{X \to Y}, D_Y) = \mathbb{E}_{y \sim P_{Data}(y)} \left[ log D_Y(y) \right]$$
 (3-14)

$$+ \mathbb{E}_{x \sim P_{Data}(x)} \left[ log(1 - D_Y(G_{X \to Y}(x))) \right]$$
 (3-15)

$$L_{adv}(G_{Y \to X}, D_X) = \mathbb{E}_{x \sim P_{Data}(x)} \left[ log D_X(x) \right]$$
 (3-16)

$$+ \mathbb{E}_{y \sim P_{Data}(y)} \left[ log(1 - D_X(G_{Y \to X}(y))) \right]$$
 (3-17)

(3-18)

对于重构损失,域 X 中的每一个样本 x 都可以通过主任务和对偶任务(或交换)的级联重新恢复为 x,因此重构损失可以表示为

$$L_{cyc}(G_{X \to Y}, G_{Y \to X}) = \mathbb{E}_{x \sim P_{Data}(x)} \left[ \left| \left| G_{Y \to X}(G_{X \to Y}(x)) \right| \right|_{1} \right]$$
(3-19)

$$+ \mathbb{E}_{y \sim P_{Data}(y)} \left[ \left| \left| G_{X \to Y} (G_{Y \to X}(y)) \right| \right|_1 \right]$$
 (3–20)

如图 3-3所示,输入依次经过两个级联的生成器后,得到的输出和输入计算重构损失,之后梯度沿着两个生成器反向传播,并对两个生成器同时更新参数。对两个损失函数加入权重后,最终的损失函数为

$$L_{full} = L_{adv}(G_{X \to Y}, D_Y) + L_{adv}(G_{Y \to X}, D_X)$$
 (3-21)

$$+ \lambda_{cyc} L_{cyc}(G_{X \to Y}, G_{Y \to X}) \tag{3-22}$$

#### 3.4.4 门控卷积网络和身份损失

为了将 CycleGAN 应用到语音转换中,作者提出了在网络中使用门控卷积网络 (Gated CNN) 以及一个额外的身份损失函数 (Identity Loss)。语音中的一个主要特

性就是语音中含有序列和层级的结构关系,例如发声和不发声 (voiced/unvoiced),音素和词素 (phonemes/morphemes)。一个对该特性建模的有效方法是使用 RNN,但是 RNN 在训练和计算速度上都不如 CNN。因此作者提出在 CycleGAN 中使用门控卷积网络。门控卷积网络既可以在序列数据上并行计算,同时也在语言和语音建模上较为成功。在门控卷积网络中,选用门控线性单元 (Gated Linear Unit, GLU)作为激励函数。GLU 计算过程公式表示为

$$\mathbf{H}_{l+1} = (\mathbf{H}_l * \mathbf{W}_l + b_l) \otimes \sigma(\mathbf{H}_l * \mathbf{V}_l + c_l)$$
(3-23)

其中  $\mathbf{W}$ ,  $\mathbf{V}$ , b 和 c 是模型参数,  $\mathbf{H}_l$  是 l 层的输出,  $\otimes$  是逐元素乘法。门控机制可以允许信息被选择性地传播到下一层。

身份损失通常只用来在训练的开始阶段使用,其作用为在训练开始时尽可能缩小生成器的参数空间。该损失函数的提出考虑到对于语音转换任务而言,只需考虑转换说话人信息,而语音中的主要信息(如文本)是不改变的。因此在训练开始时首先尽可能保证生成器保留语音中的所有信息,之后再对其中的说话人信息进行着重调整,身份损失能够有效加速模型收敛和保留语义。为了保证生成器的输出始终在目标说话人的特征分布内,身份损失选择输入目标特征而非原始特征。公式如下

$$L_{id}(G_{X \to Y}, G_{Y \to X}) = \mathbb{E}_{y \sim P_{Data}(y)} \left[ \left| \left| G_{X \to Y}(y) - y \right| \right|_1 \right]$$
 (3-24)

$$+ \mathbb{E}_{x \sim P_{Data}(x)} \left[ \left| \left| G_{Y \to X}(x) - x \right| \right|_1 \right]$$
 (3–25)

# 3.5 本章小结

本章首先介绍了非平行语音转换及其常见方法,包括音素后验概率图法,对抗训练法和变分自编码器法,并对本文中用到的基于 CycleGAN 的语音转换方法进行了详细的介绍。标准的 CycleGAN 中计算重构损失时,级联的两个生成器同时进行前向和后向传播。在该设置下,转换音频通常包含有较多噪音,从而会导致较低的语音自然度和说话人相似度。下一章将会从更新过程的角度进一步分析标准 CycleGAN 的训练过程,并介绍所提出的半优化 CycleGAN 和基频辅助特征来提升模型性能。

# 第四章 基于半优化 CycleGAN 的非平行语料语音转换

## 4.1 引言

上文介绍了非平行语料语音转换的基本概念及其常见方法,并详细介绍了基于 CycleGAN 的语音转换方法。尽管这些方法极大地推动了非平行语料语音转换的技术发展,但是在目前的相关技术里转换语音的音质依旧存在较大的提升空间。

本章基于 CycleGAN 提出了一种改进的语音转换框架,该框架主要包含两个 改进: 半优化的 CycleGAN 模型 (Semi-optimized CycleGAN) 和基频辅助特征; 同 时为了提升音质,该框架使用 WaveNet 声码器替代传统声码器,使用梅尔频谱特 征代替传统的梅尔倒谱特征。半优化 CycleGAN 主要特性为两个非一致更新的生 成器,即在训练过程中,每个循环只有一个生成器被更新,另一个生成器只被用 来生成中间特征。经过对每个生成器的更新过程进行分析, 在标准 CycleGAN 中, 部分更新过程会导致生成器在计算损失时受到带有噪声标签的影响,并且不同的 更新过程之间存在互斥现象,从而导致转换模型性能的下降。半优化 CycleGAN 即通过去除该部分更新过程来提升模型性能。参考近年语音合成和语音转换在声 码器方面的研究,我们使用梅尔频谱作为声学特征,来替代传统的梅尔倒谱系数、 非周期信息和基频这三个特征,并使用基于梅尔频谱的 WaveNet 模型作为声码器。 为了克服 CycleGAN 模型对梅尔频谱中音调信息的学习能力不足的问题,提出在 训练过程中使用基频特征作为梅尔频谱特征的辅助特征来共同训练,该改进在保 持使用梅尔频谱作为 WaveNet 的特征下,有效解决了转换音频中音调错误的问题。 本章将首先详细介绍基于梅尔频谱的 WaveNet 声码器在语音转换中的应用,然后 阐述所提出的包含半优化 CycleGAN 和基频辅助特征的非平行语料语音转换系统, 最后对实验配置和实验结果进行说明和分析。

# 4.2 基于梅尔频谱 WaveNet 的平行语料语音转换

### 4.2.1 WaveNet 声码器

如上文所述, WaveNet 是一种自回归的概率生成模型,该模型可以通过历史音频样本点,直接预测当前样本点的分布,其模型结构如图 4-1所示

其中因果卷积 (Causal Conv) 和扩张卷积 (Dilated Conv) 可以有效增加模型的输入感受域。模型由多个跳跃连接模块构成,每个模块包含一个扩张卷积和门控激励函数,其中的1\*1代表卷积核大小为1x1的卷积网络。每个模块的输出可以




图 4-1 WaveNet 模型结构图

Figure 4-1 Architecture of the WaveNet

表示为

$$\mathbf{z} = tanh(W_{f,k} * \mathbf{x} + V_{f,k}^T \mathbf{h}) \odot \sigma(W_{g,k} * \mathbf{x} + V_{g,k}^T \mathbf{h})$$
(4-1)

其中 $\mathbf{x}$ 和 $\mathbf{z}$ 分别为输入和输出向量,k 代表层编号,f 和 g 分别代表门控激励函数中的滤波器和门, $W_{f,k}$ , $W_{g,k}$ , $V_{f,k}^T$ , $V_{g,k}^T$  是可学习的权重矩阵,\* 是卷积操作, $\odot$  是逐元素的乘法操作, $\sigma$  是 sigmoid 函数,h 表示全局条件向量。全局条件向量在 WaveNet 生成过程保持不变,常用于多说话人模型中的说话人条件。对于局部特征来说,条件特征从单个向量变为了第二个特征序列  $h_t$ ,该序列通常以帧为单位,因此采样率会低于音频信号,例如语音合成系统中的语义特征或者声码器中的声学特征。通常会先将局部条件特征序列通过转置卷积或重复操作来将条件特征的采样率调整至与音频信号相同  $\mathbf{y} = f(\mathbf{h})$ ,然后每一个模块的输出可变为


$$\mathbf{z} = tanh(W_{f,k} * \mathbf{x} + V_{f,k} * \mathbf{y}) \odot \sigma(W_{g,k} * \mathbf{x} + V_{g,k} * \mathbf{y}) \tag{4--2}$$

此时  $V_{f,k}$ \*y 和  $V_{g,k}$ \*y 是一个 1x1 卷积层。整个网络的最终输出是一个 softmax 层,输出一个 256 维度的概率向量。因为音频的采样点通常是浮点数,为了能够降低建模复杂度,需要首先用  $\mu$  – law 算法将浮点采样点分为 256 类,将音频变为一个 256 维的特征向量序列,具体公式如下

$$f(x_t) = sign(x_t) \frac{ln(1 + \mu |x_t|)}{ln(1 + \mu)}$$
(4-3)

其中 $x_t$ 为t时刻的采样点,值域为[-1,1] sign 函数返回 $x_t$ 的正负符号, $\mu$ 代表压缩的类别数,这里 $\mu$ 取 256。

### 4.2.2 梅尔频谱特征转换



b) Mel-spectraogram based Voice Conversion

图 4-2 梅尔频谱语音转换和传统语音转换对比图

Figure 4–2 Comparison of the Mel-spectrogram based Voice Conversion and the conventional Voice Conversion

对于基于梅尔频谱的语音转换,可以使用任何转换模型将原始说话人的梅尔频谱特征转换为目标说话人,再通过 WaveNet 生成波形。该方法与传统语音转换方法的区别如图 4-2所示,在传统的语音转换中,通过传统声码器会从语音中提取三个特征:梅尔倒谱系数 (Mgc),非周期信号 (bap) 和基频 (F0)。其中 Mgc 使用转换模型进行转换,bap 保持不变,F0 使用线性变换。处理后的三个特征再通过数字信号声码器或神经网络声码器进行波形生成。当使用梅尔频谱作为特征时,则直接从音频中提取梅尔频谱,然后将其作为转换特征进行训练和转换,声码器也直接从梅尔频谱中恢复波形。梅尔频谱是将频谱映射到梅尔刻度 (Mel scale) 后取前 k 维得到的特征,梅尔刻度是基于彼此等距的听众对音高 (pitch) 的感性判断的刻度。

在<sup>[68]</sup> 中,作者在平行语料的语音转换任务中对比了不同声学特征和声码器配置下转换语音的性能。如图 4-3所示。图 4-3a为自然度主观意见分实验,其中bdl-slt 和 clb-slt 分别为跨性别说话人组和同性别说话人组。在所示的各组对照组中, N 为自然音频, WNS 为真实梅尔频谱特征的 WaveNet 合成音, WNC 为真实梅

尔倒谱特征的 WaveNet 合成音,WCS 为转换梅尔频谱的 WaveNet 合成音,WCC 为转换梅尔倒谱特征的 WaveNet 合成音,MCC 为转换梅尔倒谱特征的 STRAIGHT 合成音。可以看出在梅尔倒谱特征中,STRAIGHT 表现要优于 WaveNet,但基于梅尔频谱的 WaveNet 不论在反合成还是在转换特征上合成,自然度都要好于数字信号声码器。图 4-3b和图 4-3c展示了对转换语音相似度的偏好测试结果,可以看出不论是同性别还是跨性别上,基于梅尔频谱的 WaveNet(Msp WaveNet) 都要明显好于基于梅尔倒谱的 WaveNet(Mcep WaveNet) 和 STRAIGHT(Mcep STRAIGHT)。




图 4-3 不同特征和声码器下语音转换对比图[68]

Figure 4–3 Comparison on Voice Conversion of different features and vocoders

不同与梅尔倒谱,梅尔频谱不光包含了内容信息,还包含了音调信息,相当于将三个特征整合到了一起。因此,当使用梅尔频谱作为声学特征时,基频信息被隐性转换,因此该转换会比线性转换拥有更复杂的音调转换能力,如前文所述,在平行语音转换中,先前的工作已经证明了在有监督的条件下,梅尔频谱的音调转换能力要优于线性变换。但在无监督的条件下,由于没有真实标签,同时 CycleGAN的训练方式限制了生成器对局部信息的转换,导致模型较难从梅尔频谱中学习到基频表示。因此基频的隐形转换拥有较大的难度。在我们的中文语音转换实验中,转换音频通常存在音调错误的问题,尤其在男性转男性的实验中。我们提出使用基频辅助特征来提升模型的音调表示和转换能力,进而解决音调错误的问题。

# 4.3 基于半优化 CycleGAN 的非平行语料语音转换系统

本文提出的改进框架,主要基于 CycleGAN 模型和基于梅尔频谱的语音转换,即:使用梅尔频谱作为声学特征, CycleGAN 作为语音转换模型, WaveNet 作为神




图 4-4 基于半优化 CycleGAN 的语音转换系统结构图

Figure 4-4 Architecture of the semi-optimized CycleGAN based Voice Conversion

经网络声码器,以实现高音质的非平行语音转换。结合上一节提出的现有框架的缺陷和不足,可以得出改进框架主要存在的两个挑战: 低音质的转换语音和非平行梅尔频谱转换中的发音错误问题。针对两个挑战,本文分别提出半优化 CycleGAN和基频辅助特征。在本节中,我们首先从最小更新过程的角度分析标准 CycleGAN,再介绍半优化 CycleGAN。之后,再介绍使用基频辅助特征来解决音调转换错误的问题。

#### 4.3.1 半优化周期一致性生成对抗网络

我们定义模型在训练过程中可以拆分为最小的前向计算和反向梯度回传的过程作为一个最小更新过程。从图 4-5可以看出,对于每个生成器而言,一共有四个不同的最小更新过程来帮助模型训练,其中 (a) 和 (b) 都来自于重构损失,(c) 和 (d) 分别来自于对抗损失和身份损失。这里我们只考虑单个生成器 (以  $G_{X\to Y}$  为例)。对每个最小更新过程进行分析,可以注意到对于 (b) 和 (d),生成器的输出都

(a) 
$$x \xrightarrow{G_{X o Y}} \hat{y} \xrightarrow{G_{Y o X}} \tilde{x} \xrightarrow{L_{cyc}} x$$

(b)  $y \xrightarrow{G_{Y o X}} \hat{x} \xrightarrow{G_{X o Y}} \tilde{y} \xrightarrow{L_{cyc}} y$ 

(c)  $x \xrightarrow{G_{X o Y}} \hat{y} \xrightarrow{D_Y} P(\hat{y}) \xrightarrow{L_{adv}} 1$ 

(d)  $y \xrightarrow{G_{X o Y}} \hat{y} \xrightarrow{L_{id}} y$ 

图 4-5 标准 CycleGAN 中最小更新过程示意图

Figure 4-5 Schematic diagram of minimum update processes in conventional CycleGAN

有一个真实标签来计算损失。然而对于 (a) 和 (c),生成器是不存在一个真实的标签的,并且其损失是由相连的下一个模型的梯度反传间接得到的。在 (c) 中,生成器和判别器对抗训练,即当判别器尽可能去区分预测特征和真实特征时,生成器生成样本尽可能去欺骗判别器。由于判别器本身在训练时存在样本和真实标签对,即真实特征和标签 1。因此通过对判别器输入预测特征,则可以得到预测特征和真实特征之间分布的误差。该误差通过梯度反传至生成器的输出,则可以近似预测特征的损失,使生成器的输出的数据分布更接近真实特征。然而,不同于 (c),(a) 的下一个模型(即对偶的生成器  $G_{Y \to X}$ )并没有样本和真实标签对的训练数据,因此经下一个模型反向传递的梯度无法保证能够很好地近似预测特征的损失;另一方面,对偶的生成器在其身份损失的训练过程中(即更新过程 (d)),会输入和输出其目标特征,其反传的梯度会更接近于对偶生成器的目标特征分布,从而使得接近于,这会影响当前模型训练,考虑到其可能带来的优点,更新过程 (a) 会对模型带来更多的负面影响。

因此我们对重构损失的训练策略进行了调整。如图 4-6所示,我们去除了每个生成器的更新过程 (a)。因此对于每个循环,两个级联的生成器都会进行前向传播,但是只有第二个生成器会反向传播并更新,此时第一个生成器只为第二个生成器生成带噪声的预测输入特征。我们称之为'半优化'。重构损失公式变为

$$L_{cvc}(G_{X\to Y}, G_{Y\to X}) = L_{semicvc}(G_{X\to Y}) + L_{semicvc}(G_{Y\to X})$$
(4-4)

其中




图 4-6 标准 CycleGAN 和半优化 CycleGAN 重构损失函数的对比图 Figure 4-6 Comparison of Cycle-consistency loss between conventional CycleGAN and Semi-optimized CycleGAN

$$L_{semicyc}(G_{X \rightarrow Y}) = \mathbb{E}_{y \sim P_{Data}(y)} \left[ \left| \left| G_{X \rightarrow Y}(G_{Y \rightarrow X}(y)) \right| \right|_{1} \right] \tag{4-5}$$

$$L_{semicyc}(G_{Y \to X}) = \mathbb{E}_{x \sim P_{Data}(x)} \left[ \left| \left| G_{Y \to X}(G_{X \to Y}(x)) \right| \right|_{1} \right] \tag{4--6}$$

在两次不同的循环中,分别只有一个生成器作为优化对象。在实验中,我们发现半优化机制可以显著地减低噪声并提升转换语音自然度和说话人相似度。

### 4.3.2 基频辅助特征

我们使用梅尔频谱作为声学特征出于两个原因,一是其作为条件特征可以在 WaveNet 上生成相比梅尔倒谱和数字信号声码器更高音质的音频,二是其本身包含了基频信息,因此可以使用神经网络进行更为复杂的基频隐性转换。然而如前文所述,梅尔频谱直接作为 CycleGAN 的声学特征时存在发音错误的问题。主要原因分析如下。

如前文所述, CycleGAN 模型对说话人迁移的实现主要来自于对抗损失, 其中判别器通过输入声学特征片段, 输出 0 到 1 之间的概率值来判断是否接近真实特征的分布。在经过大量的数据训练后, 判别器能够对声学特征中的全局信息(如

说话人信息)有较强的判别能力,而随时间维度变化的局部信息(如语义,音调)在大量数据下很容易会被模型平均掉,使模型对梅尔频谱中基频信息的表达学习较弱,从而导致转换特征存在发音错误的问题。理论上,如果加强判别器对序列建模的能力,如引入 RNN,可以使得模型对音调的判别能力增加,但这样做会使判别器对同为局部信息的语义的判别能力也会增加,而语义信息是希望模型进行平均的。总的来说,发音错误的问题的改善需要通过不增加模型复杂度的前提下提升模型对梅尔频谱中基频信息表示的学习能力。本文提出使用基频辅助特征来帮助模型更好地实现基频学习和转换。如图 4—4所示,在训练阶段,梅尔频谱和基频特征被同时从原始音频和目标音频中提取。我们将两个特征拼接在一起,并将其输入到生成器和判别器来同时训练。在测试阶段,两个特征被同时从原始音频中分析并转换,但只有预测的梅尔频谱被用来作为条件特征进行波形生成。在实验中,基频辅助特征的引入有效地改善了合成音频中发音错误问题。

## 4.4 实验分析

### 4.4.1 实验配置

我们在中文语音转换任务上评估了半优化 CycleGAN 和基频辅助特征的效果。 所使用的中文数据集包含四个说话人,两个男性说话人和两个女性说话人。所有 训练和测试音频数据均录制于标准录音环境,且四个说话人都是以中文为母语的 标准普通话说话人。每个说话人的语音数据分为训练集、开发集和测试集,分别 包含 2000 句,100 句和 20 句,每句话音频长度在 10s 以内。任意两个说话人的 训练集数据均为非平行文本。音频采样率为 16k。实验中特征首先通过 WORLD 声码器提取 513 维的频谱特征,513 维的非周期信息和 1 维的基频特征,之后用 librosa<sup>[75]</sup> 和 pysptk<sup>[76]</sup> 工具包提取 80 维的梅尔频谱特征和 24 维的梅尔倒谱特征。 帧移为 5ms。注意到 Tacotron2 和平行语音转换任务中都使用了 12.5ms 帧移提取 特征。然而在我们的实验中,12.5ms 的帧移会导致发音不完全或音素缺失的现象 出现。我们因此使用 5ms 帧移来使用更细的频谱粒度来解决该问题。虽然 5ms 的 音质相比 12.5ms 相对较差,但是发音不完全的问题相比音质的下降更为严重。

首先使用每个说话人的训练数据各训练一个说话人相关的 WaveNet 声码器。 其中 WaveNet 模型包含 4 个神经网络块,每个块有 6 层神经网络。残差连接和门 控层的隐层节点数为 512,输出层的隐层节点数为 256。我们使用 10 个逻辑分布 的混合逻辑分布来预测样本点分布。对于半优化 CycleGAN,我们的模型结构如 图 4-7所示,相比标准 CycleGAN 的网络结构,我们根据声学特征的帧移和维度 对结构进行了调整:我们将生成器中残差块的数量和卷积层的通道数乘 2,同时




图 4-7 半优化 CycleGAN 网络结构图

Figure 4-7 Architecture of the Semi-optimized CycleGAN

为了平衡生成器和判别器的对抗训练,判别器中四个降采样层的通道数都修改为64。图中卷积层的标识 k, s, c 分别代表卷积核 (kernel), 步长 (stride) 和频道数 (channel)。生成器我们使用的是一维卷积, 因为一维卷积在抓取特征维度的总体关系的同时,更能够学习到特征的动态变化,因此在语音转换的任务中常使用一维卷积作为转换网络; 然而在语音的后处理任务 (Postfilter) 中,二维卷积更为常用,因为其更适合在改变特征形状的同时保留特征的原始结构,因此判别器使用二维卷积构建。网络中 Instance Normalization(IN) 是一种归一化方法,常用于风格迁移的任务中,其与常见的 Batch Normalization(BN) 有所区别。BN 注重对每个 batch 进行归一化,保证数据的分布一致,因为判别模型中结果取决于数据的整体分布。但是在风格迁移的任务中,生成结果主要依赖于具体的每个实例,所以对整体进行归一化并不适合用在风格迁移中,因此 IN 是对输入的高 (Height) 和宽 (Width) 进行归一化。由于 IN 的训练和测试情况相同,不存在 BN 的不一致问题,因此也

没有需要更新的参数。计算公式如下

$$y_{bchw} = \frac{x_{bchw} - \mu_{bc}}{\sqrt{\sigma_{bc}^2 + \epsilon}} * \gamma + \beta \tag{4-7}$$

其中 bchw 分别代表特征的四个维度:batch,channel,height,width。x 和 y 分别为输入和输出。 $\gamma$  和  $\beta$  是超参数。 $\mu_{bc}$  和  $\sigma_{bc}^2$  计算方式如下

$$\mu_{bc} = \frac{1}{HW} \sum_{w=1}^{W} \sum_{h=1}^{H} x_{bchw}$$
 (4–8)

$$\sigma_{bc}^2 = \frac{1}{HW} \sum_{w=1}^{W} \sum_{h=1}^{H} (x_{bchw} - \mu_{bc})^2$$
 (4-9)

Pixel Shuffler 是一种卷积网络中的升采样方法,其通过对特征矩阵进行变换和转置操作,将特征图的形状由 (B,  $f_1*f_2*C$ , H, W) 转变为 (B, C,  $f_1*H$ ,  $f_2*W$ ).

数据载入部分我们使用了与 CycleGAN-VC 相同的策略,即在训练数据中随机截取连续 128 帧的特征片段。所有网络都使用 Adam 优化器进行训练。训练 batch 大小设置为 4。生成器和判别器的初始学习率分别为 0.01 和 0.005,不使用任何学习率调节策略。模型共训练 350k 步,身份损失只参与训练开始的前 10k 步。同时为了增强模型的鲁棒性,在预测时,会将原始声学特征序列拆分为重叠的 128 帧片段,然后依次输入生成器,将生成的每个片段的中间部分提取出来,将他们拼接成最终的转换特征序列。

#### 4.4.2 客观评测

本文首先采用梅尔频谱距离 (Mel-spectrogram Distorsion, Msd) 来判断转换模型在测试集上对特征转换的接近程度。由于 CycleGAN 对抗学习的特性,其训练过程往往是不稳定的,模型性能与训练时长并不成正比关系。因此我们记录了训练阶段模型在测试集上的梅尔频谱距离,频谱距离的计算使用了平行的测试数据,这些数据不会参与模型训练。计算距离前会先用 DTW 算法对特征序列长度进行对齐。我们在跨性别实验上对比了半优化 CycleGAN 和标准 CycleGAN。实验结果如图 4–8所示。我们可以发现半优化 CycleGAN 所转换的梅尔频谱更接近目标特征,并且半优化 CycleGAN 的收敛曲线更为平稳。在实际实验中,半优化 CycleGAN 也更容易训练和优化。

为了验证基频转换的效果,在平行测试集上分别用 WORLD 声码器从转换音 频和目标音频中提取基频特征,统计各自的基频分布以及对齐后的标准误差。如




图 4-8 标准 CycleGAN 和半优化 CycleGAN 在训练过程中梅尔频谱距离的对比 Figure 4-8 Comparison of Msp distance between conventional CycleGAN and SoCycleGAN during training

表 1 所示, 其中 Source, Target 分别代表原始真实特征和目标真实特征, Linear 代表线性变换的基频特征, Proposed w/o LFO 代表没有使用基频辅助特征转换的基频, Proposed 代表使用了基频辅助特征后转换的基频。可以发现相比于线性变换,基频辅助特征所转换的基频误差有较为明显的降低,同时基频分布也较接近目标的基频分布。我们认为这是因为:(1)梅尔频谱可以实现基频的隐式转换,从而可以对基频进行比线性变换更复杂的变换映射;(2)辅助特征通过引入显示的基频特征,可以帮助模型学习梅尔频谱中和基频信息高度相关的隐含表示,进而提升基频的转换能力。

### 4.5 主观评测

为了对系统的转换效果进行测试,我们采用较为普遍的主观听音测试来评测转换语音的质量。所有的听音测试在同性别和跨性别上都进行了测试,并从测试集中随机选择了十句话让测试人员评测。每一句话在每一次测试中被至少六个测

Methods	RMSE (Hz)	Mean (Hz)	Std (Hz)
Target	0	133.25	34.72
Source	65.12	236.11	55.00
Linear	17.13	127.10	28.58
Proposed w/o LF0	17.44	124.66	27.74
Proposed	16.69	126.31	29.82

## a) 女性说话人转男性说话人

a) Female to male

Methods	RMSE(Hz)	Mean (Hz)	Std (Hz)
Target	0	236.11	55.00
Source	67.10	133.25	34.72
Linear	34.13	248.04	67.04
Proposed w/o LF0	32.51	254.71	59.53
Proposed	30.37	248.66	58.92

### b) 男性说话人转女性说话人

b) Male to female

表 4-1 Comparison of MSE, mean and standard deviation between target and converted F0 Table 4-1 转换基频和目标基频之间误差、均值和方差的对比

试人员评价。不同系统的转换音频以随机顺序提供给测试人。测试人皆是以普通话为母语的说话人。为了验证所提框架和改进的有效性,我们使用模型简化测试(Ablation study)来比较不同系统。所比较的系统实验配置如下:

- 1. N: 真实语音
- 2. Re: 真实语音提取的梅尔频谱特征,用 WaveNet 合成
- 3. B: 标准 CycleGAN 预测的梅尔倒谱系数特征,用 WORLD 合成 (基线系统, baseline)
- 4. P: 半优化 CycleGAN 预测的梅尔频谱特征,引入基频辅助特征,用 WaveNet 合成
- 5. P w/o SoCycleGAN: 标准 CycleGAN 预测的梅尔频谱特征,引入基频辅助特征,用 WaveNet 合成
- 6. P w/o F0: 半优化 CycleGAN 预测的梅尔频谱特征,无基频辅助特征,用 WaveNet 合成

为了评测自然度,我们使用平均主观意见分(Mean Opinion Score, MOS)测试。系统 N 和 Re 分别作为语音音质的上限分数和声码器的上限分数。除此之外我们也测试了所提出的系统在小数据集上的表现,即在相同配置下 100、200、500 句话训练集的效果。为了评测相似度,我们使用相同/不相同测试(same/different test)。




图 4-9 不同方法在语音自然度上的平均主观意见分对比图

Figure 4–9 MOS comparison among different methods

图 4-9展示了 MOS 测试的结果。对比系统 P 和 P w/o SoCycleGAN,可以看到半优化 CycleGAN 在自然度上的提升。从 P 和 P w/o F0 的对比,也能发现基频辅助特征的提升,尤其在男性到男性的实验中(在该实验中音调错误问题最为严重)。图 4-10展示了所提出系统在不同训练数据量下的性能对比。2000,500,200 和100 分别代表训练数据集的大小。SWN 代表单说话人 WaveNet,是由 2000 句特定说话人的训练集训练而成,用以测试半优化 CycleGAN 的上界。MWN 代表多说话人的 WaveNet,是由十个中文说话人十几小时数据训练而成。可以发现提出的系



图 4-10 不同大小训练数据集在语音自然度上的平均主观意见分对比图 Figure 4-10 MOS comparison among different training data set




图 4-11 不同系统在四个说话人对上的相似度对比图

Figure 4–11 Comparison of similarity to target speaker in four speaker pairs

统在至少 500 句的训练集上可以生成较高音质的转换音频。注意到我们对于小数据集没有对模型结构进行调整,因此在音质上仍有提升的空间。相似度实验的结果在图 4-11展示,可以发现所提框架在四个说话人对上都有更好的相似度表现。

# 4.6 本章小结

本章介绍了一种高音质的非平行语音转换框架,针对标准 CycleGAN-VC 存在的两个问题,本章提出半优化 CycleGAN 和基频辅助特征,并说明了这两个结构可以在基于梅尔频谱的 WaveNet 声码器下生成高音质的转换语音。对比标准 CycleGAN,半优化 CycleGAN 对语音自然度和相似度有着较为明显的提升。基频辅助特征的引入同样也帮助模型更好地从梅尔频谱中学习到基频信息的表示和转换。主观评测和客观评测表示,所提出的系统表现优于标准 CycleGAN 和 WORLD 声码器的系统或标准 CycleGAN 和 WaveNet 声码器的系统。下一章将介绍该框架在难度更大的语音转换任务:跨语种转换任务上的优化。

## 第五章 基于说话人特征的跨语种语音转换优化方法

### 5.1 引言

上文介绍了本文提出了基于半优化 CycleGAN 的非平行语料语音转换系统,该框架可以在一般非平行语料的语音转换任务上得到较高的音质。然而,当原始说话人和目标说话人两个领域的差距较大时,转换的难度就会显著增加,差距可以体现在说话人信息,语速,语义,音调等。在这种情况下,转换语音的音质会有明显的下降,甚至会无法训练。另一方面,实际应用场景中,两个差距较大的领域是比较常见的,之前实验中的数据都是在专业录音环境下录制的平稳朗读语音,属于较为理想的情况。因此,对领域差距较大情况下的语音转换任务进行优化具有较高的实际应用价值和研究价值。本章将对其中较为极端的任务作为研究对象,即跨语种的语音转换。在该任务中,两个领域不仅是说话人信息不同,在语义信息上也具有较大的差异,这对模型性能提出了挑战。

本章提出一种基于说话人特征的跨语种语音转换方法,以第三章介绍的CycleGAN-VC方法为基础,在CycleGAN模型中引入说话人识别机制。首先需要先训练一个说话人识别模型,之后使用模型中的d-vector提取器来作为Cycle-GAN中判别器的前置模型,使得判别器可以只使用说话人信息作为判别标准。实验证明,引入说话人特征的语音转换方法可以有效实现在保留语义的前提下实现说话人语音转换,有效提升模型性能。

在接下来的内容中,将首先对跨语种语音转换和相关工作进行简要介绍,然后对说话人识别及其相关特征进行说明,之后将详细介绍本章提出的引入说话人特征的跨语种语音转换优化方法,最后对实验配置及其结果进行分析。

### 5.2 跨语种语音转换

#### 5.2.1 跨语种语音转换概述

根据转换语言条件的不同,可以将语音转换分为两类:单语种语音转换和跨语种语音转换。在单语种语音转换中,训练集中原始说话人和目标说话人的语言是相同的,在测试时也是同一种语言。相对的,跨语种语音转换则是原始说话人和目标说话人的语言不同,在此基础上可以将其再分为两类:一类是原始说话人的训练集是双语种的,其中一个语种和目标说话人一致;另一类则是完全不相同。早期在跨语种语音转换上的研究多基于第一类情况,在本章我们则将以第二类为研

究对象。跨语种语音转换具有较好的发展和应用前景,作为无监督学习任务,其可以实现让一个不会说某种语言的说话人以他的声音说该语言。在语音翻译中,通常需要将某个说话人的语音翻译为另一种语言的语音,然而翻译语音通常不是该说话人的声音,跨语种语音转换便可以作为补充,完善语音翻译的整个环节。

尽管跨语种的语音转换的研究仍处于初步阶段,但研究人员针对跨语种的特点,提出了一些有效的方法。在<sup>[77]</sup> 中,一个双语种的转换模型在目标语言的平行训练数据上训练,这需要原始说话人的训练数据不仅包含原始语种,也包含目标语种。然而,事实上双语种说话人的双语数据是较难获得的。因此一些用于在非平行数据中找到对应的原始-目标帧的非平行对齐技术被开发出来,例如单元选择<sup>[31,78]</sup> 和迭代对齐法<sup>[20,79]</sup>。但是这些方法由于不准确性使得转换性能只处于中等。基于声道长度归一化的音素映射方法也被提出<sup>[19,80]</sup>,这些方法中弯折函数是通过原始和目标特征之间最接近的音素或声学类来估计的。研究人员也提出了基于音素后验概率图的方法<sup>[56,81]</sup>,该方法使用单语种或双语种的音素字典来作为中间的说话人无关特征,实现跨语种的转换。

#### 5.2.2 跨语种语音转换的难点

如前文所述,跨语种语音转换作为一个无监督任务,是非平行语料语音转换的一个特殊任务。相比于通常的非平行语料语音转换,跨语种语音转换转换难度更大,目前方法的效果也都不尽如人意。主要难度体现在以下两个方面。




图 5-1 跨语种语音转换和标准语音转换对比图

Figure 5-1 Comparison of cross-lingual Voice Conversion and standard Voice Conversion

 不同语种之间文本信息不一致导致较难匹配。由于跨语种的语音转换涉及 到两种不同的语言,因此平行语料的语音转换方法将完全不适用。另一方 面若使用非平行的对齐方法,语种之间的巨大差异也会导致对齐准确度的

- 下降。因此如何找到有效的单元匹配方式或无监督的训练方式是跨语种语音转换面临的主要挑战。
- 差异较大的声学特征与 CycleGAN 训练机制的矛盾。该矛盾分为两个方面。 如前文所述, CycleGAN 之所以能够实现语音转换任务, 判别器在其中有 着关键的作用。判别器在训练时,会分别输入正例和负例,对应训练标签 1和0,其中正例是目标说话人的真实特征序列,负例是从原始说话人声学 特征经生成器转换的目标说话人的转换特征序列,判别器的目标是尽可能 地区分正例和负例。生成器在训练时会将生成的目标说话人转换特征传递 给判别器,并将判别器的判别结果与1计算损失,来衡量转换特征和真实 目标特征之间的差距,然后将梯度回传给生成器,这样生成器下次在遇到 类似输入时,就会生成更接近判别器正例的转换特征。从图5-1中可以注意 到,在跨语种语音转换中,判别器的正例是目标语种的目标说话人特征序 列,而负例是原始语种的目标说话人特征序列。当判别器尝试区分正负例 时,总是会尝试以区分度最大的信息作为判别要素,此时当语种信息的差 异化大于说话人信息的差异化时, 判别器就会转变为一个语种分类器, 进 而导致生成器无法从判别器中得到正确的梯度, 因此在基线试验中, 经常 会导致模型在训练时无法训练成功:输入中文,生成器会输出无意义的英 文语音。另一方面,语种的差异也会导致跨语种语音转换没有一个标准的 对偶任务。如图5-1中左图所示,主任务为将说话人 X 的 A 语言转为说话 A 语言,而实际上对偶任务则是说话人Y 的B 语言转为说话人X 的B 语 言。这样的不完全对偶性也增加了 CycleGAN 在跨语种语音转换任务上的 难度。

- 5.3 说话人识别
- 5.3.1 说话人识别概述
- **5.3.2** d-vector 说话人特征
- 5.4 引入说话人特征的跨语种语音转换
- 5.4.1 语种无关的 d-vector 提取器训练
- 5.4.2 d-vector 提取器和 CycleGAN 的结合
- 5.5 实验分析
- 5.5.1 实验配置
- 5.5.2 引入说话人特征的有效性检验
- 5.5.3 说话人分类模型的比较
- 5.6 本章小结

# 全文总结

### **Maxwell Equations**

选择二维情况,有如下的偏振矢量:

$$E = E_{z}(r,\theta)\hat{z} \tag{-1a}$$

$$H = H_r(r,\theta)\hat{r} + H_{\theta}(r,\theta)\hat{\theta} \tag{-1b}$$

对上式求旋度:

$$\nabla \times E = \frac{1}{r} \frac{\partial E_z}{\partial \theta} \hat{r} - \frac{\partial E_z}{\partial r} \hat{\theta}$$
 (-2a)

$$\nabla \times H = \left[ \frac{1}{r} \frac{\partial}{\partial r} (rH_{\theta}) - \frac{1}{r} \frac{\partial H_r}{\partial \theta} \right] \hat{z} \tag{-2b}$$

因为在柱坐标系下, $\frac{-}{\mu}$ 是对角的,所以 Maxwell 方程组中电场 E 的旋度:

$$\nabla \times E = i\omega B \tag{-3a}$$

$$\frac{1}{r}\frac{\partial E_z}{\partial \theta}\hat{r} - \frac{\partial E_z}{\partial r}\hat{\theta} = i\omega\mu_r H_r \hat{r} + i\omega\mu_\theta H_\theta \hat{\theta}$$
 (-3b)

所以 H 的各个分量可以写为:

$$H_r = \frac{1}{\mathrm{i}\omega\mu_r} \frac{1}{r} \frac{\partial E_z}{\partial \theta} \tag{-4a}$$

$$H_{\theta} = -\frac{1}{\mathrm{i}\omega\mu_{\theta}} \frac{\partial E_z}{\partial r} \tag{-4b}$$

同样地,在柱坐标系下, $\bar{\epsilon}$ 是对角的,所以 Maxwell 方程组中磁场 H 的旋度:

$$\nabla \times H = -\mathrm{i}\omega D \tag{-5a}$$

$$\left[\frac{1}{r}\frac{\partial}{\partial r}(rH_{\theta}) - \frac{1}{r}\frac{\partial H_{r}}{\partial \theta}\right]\hat{z} = -\mathrm{i}\omega\bar{\epsilon}E = -\mathrm{i}\omega\epsilon_{z}E_{z}\hat{z} \tag{-5b}$$

$$\frac{1}{r}\frac{\partial}{\partial r}(rH_{\theta}) - \frac{1}{r}\frac{\partial H_r}{\partial \theta} = -\mathrm{i}\omega\epsilon_z E_z \tag{-5c}$$

由此我们可以得到关于 Ez 的波函数方程:

$$\frac{1}{\mu_{\theta}\epsilon_{z}} \frac{1}{r} \frac{\partial}{\partial r} \left( r \frac{\partial E_{z}}{\partial r} \right) + \frac{1}{\mu_{r}\epsilon_{z}} \frac{1}{r^{2}} \frac{\partial^{2} E_{z}}{\partial \theta^{2}} + \omega^{2} E_{z} = 0 \tag{-6}$$

## 绘制流程图

图 –2 是一张流程图示意。使用 tikz 环境,搭配四种预定义节点(startstop、process、decision 和io),可以容易地绘制出流程图。




图 -2 绘制流程图效果

Figure –2 Flow chart

## 参考文献

- [1] KINNUNEN T, LI H. An overview of text-independent speaker recognition: From features to supervectors[J]. Speech communication, 2010, 52(1): 12-40.
- [2] 刘蕊. 发声的生理结构和嗓音的保护[J]. 民族音乐, 2009(6): 111-112.
- [3] NURMINEN J, SILÉN H, POPA V, et al. Voice Conversion[G/OL]// RAMAKRISHNAN S. Speech Enhancement, Modeling and Recognition- Algorithms and Applications. Rijeka: IntechOpen, 2012. https://doi.org/10.5772/3733 4. DOI: 10.5772/37334.
- [4] GIBIANSKY A, ARIK S, DIAMOS G, et al. Deep voice 2: Multi-speaker neural text-to-speech[C]//Advances in neural information processing systems. [S.l.: s.n.], 2017: 2962-2970.
- [5] PING W, PENG K, GIBIANSKY A, et al. Deep voice 3: 2000-speaker neural text-to-speech[J]. ArXiv preprint arXiv:1710.07654, 2017.
- [6] FAN Y, QIAN Y, SOONG F K, et al. Multi-speaker modeling and speaker adaptation for DNN-based TTS synthesis[C]//2015 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). [S.l.: s.n.], 2015: 4475-4479.
- [7] TAMURA M, MASUKO T, TOKUDA K, et al. Adaptation of pitch and spectrum for HMM-based speech synthesis using MLLR[C]//2001 IEEE International Conference on Acoustics, Speech, and Signal Processing. Proceedings (Cat. No. 01CH37221): vol. 2. [S.l.: s.n.], 2001: 805-808.
- [8] WU Z, SWIETOJANSKI P, VEAUX C, et al. A study of speaker adaptation for DNN-based speech synthesis[C]//Sixteenth Annual Conference of the International Speech Communication Association. [S.l.: s.n.], 2015.
- [9] YAMAGISHI J, KOBAYASHI T, NAKANO Y, et al. Analysis of speaker adaptation algorithms for HMM-based speech synthesis and a constrained SMAPLR adaptation algorithm[J]. IEEE Transactions on Audio, Speech, and Language Processing, 2009, 17(1): 66-83.

- [10] KAIN A, MACON M W. Spectral voice conversion for text-to-speech synthesis[C]//Proceedings of the 1998 IEEE International Conference on Acoustics, Speech and Signal Processing, ICASSP'98 (Cat. No. 98CH36181): vol. 1. [S.l.: s.n.], 1998: 285-288.
- [11] ARSLAN L M. Speaker transformation algorithm using segmental codebooks (STASC)[J]. Speech Communication, 1999, 28(3): 211-226.
- [12] HOLLEGAARD M V, SKOGSTRAND K, THORSEN P, et al. Joint analysis of SNPs and proteins identifies regulatory IL18 gene variations decreasing the chance of spastic cerebral palsy[J]. Human mutation, 2013, 34(1): 143-148.
- [13] AIHARA R, TAKASHIMA R, TAKIGUCHI T, et al. Individuality-preserving voice conversion for articulation disorders based on Non-negative Matrix Factorization[C]//2013 IEEE International Conference on Acoustics, Speech and Signal Processing. [S.l.: s.n.], 2013: 8037-8040.
- [14] DESAI S, BLACK A W, YEGNANARAYANA B, et al. Spectral mapping using artificial neural networks for voice conversion[J]. IEEE Transactions on Audio, Speech, and Language Processing, 2010, 18(5): 954-964.
- [15] KINNUNEN T, WU Z Z, LEE K A, et al. Vulnerability of speaker verification systems against voice conversion spoofing attacks: The case of telephone speech[C]//2012 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). [S.l.: s.n.], 2012: 4401-4404.
- [16] TODA T, CHEN L H, SAITO D, et al. The Voice Conversion Challenge 2016.[C]//Interspeech. [S.l.: s.n.], 2016: 1632-1636.
- [17] WESTER M, WU Z, YAMAGISHI J. Analysis of the Voice Conversion Challenge 2016 Evaluation Results.[C]//Interspeech. [S.l.: s.n.], 2016: 1637-1641.
- [18] LORENZO-TRUEBA J, YAMAGISHI J, TODA T, et al. The voice conversion challenge 2018: Promoting development of parallel and nonparallel methods[J]. ArXiv preprint arXiv:1804.04262, 2018.
- [19] SUNDERMANN D, NEY H. VTLN-based voice conversion[C]//Proceedings of the 3rd IEEE International Symposium on Signal Processing and Information Technology (IEEE Cat. No. 03EX795). [S.l.: s.n.], 2003: 556-559.

- [20] ERRO D, MORENO A, BONAFONTE A. INCA algorithm for training voice conversion systems from nonparallel corpora[J]. IEEE Transactions on Audio, Speech, and Language Processing, 2009, 18(5): 944-953.
- [21] YE H, YOUNG S. Voice conversion for unknown speakers[C]//Eighth International Conference on Spoken Language Processing. [S.l.: s.n.], 2004.
- [22] KAWAHARA H. Speech representation and transformation using adaptive interpolation of weighted spectrum: vocoder revisited[C]//1997 IEEE International Conference on Acoustics, Speech, and Signal Processing: vol. 2. [S.l.: s.n.], 1997: 1303-1306.
- [23] KAWAHARA H. TANDEM-STRAIGHT, a research tool for L2 study enabling flexible manipulations of prosodic information[C]//Proceedings of Speech Prosody. [S.l.: s.n.], 2008: 619-628.
- [24] MORISE M, YOKOMORI F, OZAWA K. WORLD: a vocoder-based high-quality speech synthesis system for real-time applications[J]. IEICE TRANSACTIONS on Information and Systems, 2016, 99(7): 1877-1884.
- [25] OORD A V D, DIELEMAN S, ZEN H, et al. Wavenet: A generative model for raw audio[J]. ArXiv preprint arXiv:1609.03499, 2016.
- [26] TAMAMORI A, HAYASHI T, KOBAYASHI K, et al. Speaker-Dependent WaveNet Vocoder.[C]//Interspeech. [S.l.: s.n.], 2017: 1118-1122.
- [27] OORD A V D, LI Y, BABUSCHKIN I, et al. Parallel wavenet: Fast high-fidelity speech synthesis[J]. ArXiv preprint arXiv:1711.10433, 2017.
- [28] KALCHBRENNER N, ELSEN E, SIMONYAN K, et al. Efficient neural audio synthesis[J]. ArXiv preprint arXiv:1802.08435, 2018.
- [29] VALIN J M, SKOGLUND J. LPCNet: Improving neural speech synthesis through linear prediction[C]//ICASSP 2019-2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). [S.l.: s.n.], 2019: 5891-5895.
- [30] SHUANG Z, MENG F, QIN Y. Voice conversion by combining frequency warping with unit selection[C]//2008 IEEE International Conference on Acoustics, Speech and Signal Processing. [S.l.: s.n.], 2008: 4661-4664.

- [31] SUNDERMANN D, HOGE H, BONAFONTE A, et al. Text-independent voice conversion based on unit selection[C]//2006 IEEE International Conference on Acoustics Speech and Signal Processing Proceedings: vol. 1. [S.l.: s.n.], 2006: I-I.
- [32] WU Z, VIRTANEN T, KINNUNEN T, et al. Exemplar-based unit selection for voice conversion utilizing temporal information.[C]//INTERSPEECH. [S.l.: s.n.], 2013: 3057-3061.
- [33] TAKASHIMA R, TAKIGUCHI T, ARIKI Y. Exemplar-based voice conversion in noisy environment[C]//2012 IEEE Spoken Language Technology Workshop (SLT). [S.l.: s.n.], 2012: 313-317.
- [34] WU Z, VIRTANEN T, CHNG E S, et al. Exemplar-based sparse representation with residual compensation for voice conversion[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2014, 22(10): 1506-1521.
- [35] ZHANG S, HUANG D Y, XIE L, et al. Regularized Non-negative Matrix Factorization Using Alternating Direction Method of Multipliers and Its Application to Source Separation[C]//Sixteenth Annual Conference of the International Speech Communication Association. [S.l.: s.n.], 2015.
- [36] ERRO D, MORENO A, BONAFONTE A. Voice conversion based on weighted frequency warping[J]. IEEE Transactions on Audio, Speech, and Language Processing, 2009, 18(5): 922-931.
- [37] TIAN X, WU Z, LEE S W, et al. Sparse representation for frequency warping based voice conversion[C]//2015 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). [S.l.: s.n.], 2015: 4235-4239.
- [38] TODA T, SARUWATARI H, SHIKANO K. Voice conversion algorithm based on Gaussian mixture model with dynamic frequency warping of STRAIGHT spectrum[J]. Proceedings ICASSP, IEEE International Conference on Acoustics, Speech and Signal Processing, 2001, 2: 841-844.
- [39] CHEN Y, CHU M, CHANG E, et al. Voice conversion with smoothed GMM and MAP adaptation[C]//Eighth European Conference on Speech Communication and Technology. [S.l.: s.n.], 2003.
- [40] KOBAYASHI K, TAKAMICHI S, NAKAMURA S, et al. The NU-NAIST Voice Conversion System for the Voice Conversion Challenge 2016.[C]//Interspeech. [S.l.: s.n.], 2016: 1667-1671.

- [41] STYLIANOU Y, CAPPÉ O, MOULINES E. Continuous probabilistic transform for voice conversion[J]. IEEE Transactions on speech and audio processing, 1998, 6(2): 131-142.
- [42] ARYAL S, GUTIERREZ-OSUNA R. Articulatory-based conversion of foreign accents with deep neural networks[C]//Sixteenth Annual Conference of the International Speech Communication Association. [S.l.: s.n.], 2015.
- [43] CHEN L H, LING Z H, LIU L J, et al. Voice conversion using deep neural networks with layer-wise generative training[J]. IEEE/ACM Transactions on Audio, Speech and Language Processing (TASLP), 2014, 22(12): 1859-1872.
- [44] NAKASHIKA T, TAKIGUCHI T, ARIKI Y. Voice conversion using speaker-dependent conditional restricted Boltzmann machine[J]. EURASIP Journal on Audio, Speech, and Music Processing, 2015, 2015(1): 8.
- [45] SUN L, KANG S, LI K, et al. Voice conversion using deep bidirectional long short-term memory based recurrent neural networks[C]//2015 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). [S.l.: s.n.], 2015: 4869-4873.
- [46] KANEKO T, KAMEOKA H, HIRAMATSU K, et al. Sequence-to-Sequence Voice Conversion with Similarity Metric Learned Using Generative Adversarial Networks. [C]//INTERSPEECH. [S.l.: s.n.], 2017: 1283-1287.
- [47] HSU C C, HWANG H T, WU Y C, et al. Voice conversion from unaligned corpora using variational autoencoding wasserstein generative adversarial networks[J]. ArXiv preprint arXiv:1704.00849, 2017.
- [48] KAMEOKA H, TANAKA K, KANEKO T, et al. Convs2s-vc: Fully convolutional sequence-to-sequence voice conversion[J]. ArXiv preprint arXiv:1811.01609, 2018.
- [49] TANAKA K, KAMEOKA H, KANEKO T, et al. AttS2S-VC: Sequence-to-sequence voice conversion with attention and context preservation mechanisms[C]//ICASSP 2019-2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). [S.l.: s.n.], 2019: 6805-6809.

- [50] ZHANG J X, LING Z H, JIANG Y, et al. Improving Sequence-to-sequence Voice Conversion by Adding Text-supervision[C]//ICASSP 2019-2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). [S.l.: s.n.], 2019: 6785-6789.
- [51] POLYAK A, WOLF L. Attention-based Wavenet Autoencoder for Universal Voice Conversion[C]//ICASSP 2019-2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). [S.l.: s.n.], 2019: 6800-6804.
- [52] SUN L, LI K, WANG H, et al. Phonetic posteriorgrams for many-to-one voice conversion without parallel data training[C]//2016 IEEE International Conference on Multimedia and Expo (ICME). [S.l.: s.n.], 2016: 1-6.
- [53] LIU S, SUN L, WU X, et al. The HCCL-CUHK System for the Voice Conversion Challenge 2018.[C]//Odyssey. [S.l.: s.n.], 2018: 248-254.
- [54] LU H, WU Z, LI R, et al. A Compact Framework for Voice Conversion Using Wavenet Conditioned on Phonetic Posteriorgrams[C]//ICASSP 2019-2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). [S.l.: s.n.], 2019: 6810-6814.
- [55] LIU S, CAO Y, WU X, et al. Jointly Trained Conversion Model and WaveNet Vocoder for Non-parallel Voice Conversion using Mel-spectrograms and Phonetic Posteriorgrams[J]. Proc. Interspeech 2019, 2019: 714-718.
- [56] ZHOU Y, TIAN X, XU H, et al. Cross-lingual Voice Conversion with Bilingual Phonetic Posteriorgram and Average Modeling[C]//ICASSP 2019-2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). [S.l.: s.n.], 2019: 6790-6794.
- [57] KANEKO T, KAMEOKA H. Parallel-data-free voice conversion using cycle-consistent adversarial networks[J]. ArXiv preprint arXiv:1711.11293, 2017.
- [58] KANEKO T, KAMEOKA H, TANAKA K, et al. CycleGAN-VC2: Improved CycleGAN-based Non-parallel Voice Conversion[C]//ICASSP 2019-2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). [S.l.: s.n.], 2019: 6820-6824.

- [59] KAMEOKA H, KANEKO T, TANAKA K, et al. StarGAN-VC: Non-parallel many-to-many voice conversion using star generative adversarial networks[C]// 2018 IEEE Spoken Language Technology Workshop (SLT). [S.l.: s.n.], 2018: 266-273.
- [60] KANEKO T, KAMEOKA H, TANAKA K, et al. StarGAN-VC2: Rethinking Conditional Methods for StarGAN-Based Voice Conversion[J]. ArXiv preprint arXiv:1907.12279, 2019.
- [61] HSU C C, HWANG H T, WU Y C, et al. Voice conversion from non-parallel corpora using variational auto-encoder[C]//2016 Asia-Pacific Signal and Information Processing Association Annual Summit and Conference (APSIPA). [S.l.: s.n.], 2016: 1-6.
- [62] KAMEOKA H, KANEKO T, TANAKA K, et al. ACVAE-VC: Non-parallel voice conversion with auxiliary classifier variational autoencoder[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2019.
- [63] SAITO Y, IJIMA Y, NISHIDA K, et al. Non-parallel voice conversion using variational autoencoders conditioned by phonetic posteriorgrams and d-vectors[C]// 2018 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). [S.l.: s.n.], 2018: 5274-5278.
- [64] NURMINEN J, SILÉN H, POPA V, et al. Voice Conversion[J]., 2012, 8(2): 147-158.
- [65] 杨骋, 沈媛, 张永, 等. 基于简化 STRAIGHT 模型的语音信号重构[J]. 指挥信息系统与技术, (4): 39-44.
- [66] GRIFFIN D, LIM J. Signal estimation from modified short-time Fourier transform[J]. IEEE Transactions on Acoustics, Speech, and Signal Processing, 1984, 32(2): 236-243.
- [67] DESAI S, RAGHAVENDRA E V, YEGNANARAYANA B, et al. Voice conversion using artificial neural networks[C]//2009 IEEE International Conference on Acoustics, Speech and Signal Processing. [S.l.: s.n.], 2009: 3893-3896.
- [68] CHEN K, CHEN B, LAI J, et al. High-quality Voice Conversion Using Spectrogram-Based WaveNet Vocoder.[C]//Interspeech. [S.l.: s.n.], 2018: 1993-1997.

- [69] HELANDER E E, NURMINEN J. A novel method for prosody prediction in voice conversion[C]//2007 IEEE International Conference on Acoustics, Speech and Signal Processing-ICASSP'07: vol. 4. [S.l.: s.n.], 2007: IV-509.
- [70] MOUCHTARIS A, VAN DER SPIEGEL J, MUELLER P. Non-parallel training for voice conversion by maximum likelihood constrained adaptation[C]// 2004 IEEE International Conference on Acoustics, Speech, and Signal Processing: vol. 1. [S.l.: s.n.], 2004: I-1.
- [71] LEE C H, WU C H. Map-based adaptation for speech conversion using adaptation data selection and non-parallel training[C]//Ninth International Conference on Spoken Language Processing. [S.l.: s.n.], 2006.
- [72] POVEY D, GHOSHAL A, BOULIANNE G, et al. The Kaldi speech recognition toolkit[C]//IEEE 2011 workshop on automatic speech recognition and understanding: CONF. [S.l.: s.n.], 2011.
- [73] HE D, XIA Y, QIN T, et al. Dual learning for machine translation[C]//Advances in Neural Information Processing Systems. [S.l.: s.n.], 2016: 820-828.
- [74] GOODFELLOW I, POUGET-ABADIE J, MIRZA M, et al. Generative adversarial nets[C]//Advances in neural information processing systems. [S.l.: s.n.], 2014: 2672-2680.
- [75] MCFEE B, RAFFEL C, LIANG D, et al. Librosa: Audio and music signal analysis in python[C]//Proceedings of the 14th python in science conference: vol. 8. [S.l.: s.n.], 2015.
- [76] YAMAMOTO R, FELIPE J, BLAAUW M. R9y9/pysptk: 0.1. 14[Z]. 2019.
- [77] ABE M, SHIKANO K, KUWABARA H. Statistical analysis of bilingual speaker's speech for cross-language voice conversion[J]. Journal of the Acoustical Society of America, 90(1): 76.
- [78] HAO W, SOONG F, MENG H. AA spectral space warping approach to cross-lingual voice transformation in HMM-based TTS[C]//ICASSP 2015 2015 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). [S.l.: s.n.], 2015.

- [79] ERRO D, MORENO A. Frame alignment method for cross-lingual voice conversion[C]//Eighth Annual Conference of the International Speech Communication Association. [S.l.: s.n.], 2007.
- [80] QIAN Y, XU J, SOONG F K. A frame mapping based HMM approach to cross-lingual voice transformation[C]//2011 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). [S.l.: s.n.], 2011: 5120-5123.
- [81] SUN L, WANG H, KANG S, et al. Personalized, Cross-Lingual TTS Using Phonetic Posteriorgrams.[C]//INTERSPEECH. [S.l.: s.n.], 2016: 322-326.

## 致 谢

感谢那位最先制作出博士学位论文 LATEX 模板的交大物理系同学! 感谢 William Wang 同学对模板移植做出的巨大贡献! 感谢 @weijianwen 学长一直以来的开发和维护工作! 感谢 @sjtug 以及 @dyweb 对 0.9.5 之后版本的开发和维护工作! 感谢所有为模板贡献过代码的同学们,以及所有测试和使用模板的各位同学! 感谢 LATEX 和 SJTUTHESIS,帮我节省了不少时间。

# 攻读硕士学位期间已发表或录用的论文

- [1] Chen H, Chan C T. Acoustic cloaking in three dimensions using acoustic metamaterials[J]. Applied Physics Letters, 2007, 91:183518.
- [2] Chen H, Wu B I, Zhang B, et al. Electromagnetic Wave Interactions with a Metamaterial Cloak[J]. Physical Review Letters, 2007, 99(6):63903.

# 攻读硕士学位期间参与的项目

- [1] 参与 973 项目子课题 (2007 年 6 月-2008 年 5 月)
- [2] 参与自然基金项目 (2005年5月-2005年8月)
- [3] 参与国防项目 (2005年8月-2005年10月)

# 攻读硕士学位期间申请的专利

[1] 第一发明人, "永动机", 专利申请号 202510149890.0

## 简 历

### 基本情况

某某, yyyy 年 mm 月生于 xxxx。

### 教育背景

- yyyy 年 mm 月至今, 上海交通大学, 博士研究生, xx 专业
- yyyy 年 mm 月至 yyyy 年 mm 月,上海交通大学,硕士研究生, xx 专业
- yyyy 年 mm 月至 yyyy 年 mm 月,上海交通大学,本科,xx 专业

### 研究兴趣

IATEX 排版

### 联系方式

• 地址: 上海市闵行区东川路 800 号, 200240

• E-mail: xxx@sjtu.edu.cn